第 30 卷 第 3 期
2023 年 6 月

金属功能材料
Metallic Functional Materials

Vol. 30, No. 3, p1-16
June, 2023

DOI: 10.13228/j.boyuan.issn1005-8192.20230048

单斌(SHAN Bin),**华中科技大学材料科学与工程学院教授、博士生导师、兼任中科院宁波材料所客座研究员。教育部新世纪优秀人才支持计划获得者,湖北省杰出青年基金获得者,中国稀土学会催化专业委员会委员,主持和参与了多项国家自然科学基金重点项目、面上项目、国家重大科学研究计划**(973)**青年科学家专题项目、湖北省杰出青年基金在内的多项国家及省部级项目。在** Science, Nature Communications, Angewante Chemie, Physical Review Letters **等国际权威杂志发表论文** 200 **余篇;授权发明专利** 20 **余项;主编撰写国家重点图书《材料学的纳米尺度计算模拟:从基本原理到算法实现》。获日内瓦国际发明展特别金奖、湖北省技术发明一等奖、中国稀土学会科学技术二等奖、湖北省专利银奖等奖项。主要研究方向:数据驱动的催化材料精准设计与可控制备。**

大语言模型时代的材料信息提取和数据驱动研发

单　斌[1], **李豪杰**[1], **文艳伟**[1], **陈　蓉**[2]

(1. 华中科技大学材料科学与工程学院, 湖北 武汉 430074;
2. 华中科技大学机械科学与工程学院, 湖北 武汉 430074)

摘　要: 随着数据科学在科学领域的广泛应用,获取数据的重要性越来越高。在材料学领域,相关的论文包含了大量的材料科学知识。然而,这些论文往往呈现出非结构化和高度异构的格式,这为大规模分析其中包含的信息造成了障碍。幸运的是,自然语言处理(NLP)和计算机视觉(CV)等快速发展,特别是像 ChatGPT 这样的大型预训练语言模型,展现了巨大潜力。综述了文本挖掘在材料学的一般流程和工具,包括利用 ChatGPT 等大型预训练语言模型进行知识抽取,并介绍了图像和表格信息提取。然后,讨论了数据在材料性能预测、筛选和逆向合成中的应用。最后,结合最新的大型预训练模型,展望了数据驱动材料研究的未来发展方向。

关键词: 自然语言处理(NLP);材料合成;原子层沉积(ALD);预训练模型

文献标志码: A　　**文章编号:** 1005-8192(2023)03-0001-16

Material information extraction and data-driven research in the era of large language models

SHAN Bin[1], LI Haojie[1], WEN Yanwei[1], CHEN Rong[2]

(1. School of Materials Science and Engineering, Huazhong University of Science and Technology, Wuhan 430074, Hubei, China; 2. School of Mechanical Science and Engineering, Huazhong University of Science and Technology, Wuhan 430074, Hubei, China)

Abstract: With the widespread application of data science in the scientific field, the importance of data acquisition is increasing. In the field of materials science, related papers contain a wealth of materials science knowledge. Howev-

作者简介: 单　斌(1978—),男,博士,教授;　**E-mail:** bshan@mail.hust.edu.cn;
通讯作者: 陈　蓉(1978—),女,博士,教授;　**E-mail:** rongchen@mail.hust.edu.cn

收稿日期: 2023-04-23

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

er, these papers often present a non-structured and highly heterogeneous format, which creates obstacles for large-scale analysis of the information. Fortunately, there are rapid advances in natural language processing (NLP) and computer vision (CV). In particular, large pre-trained language models such as ChatGPT show great potential. The general process and tools of text mining in materials science was reviewed, and information extraction from images and tables were introduced. Then, the application of data in materials property prediction, screening, and reverse synthesis was discussed. Finally, the future development direction of data-driven materials research was anticipated by combining with the latest large-scale pre-training models

Key words: natural language processing; material synthesis; atomic layer deposition; pre-training model

1 基于自然语言识别的材料学信息提取

数据一直是加速科学发现、解决科学问题的基本要素。近年来,随着计算能力的提高和数据科学的发展,数据驱动的材料研究带来了巨大的机会和广阔的前景。材料信息学在新材料的研究中发挥了重要的作用,已成功应用于在合金[1-2]、有机发光二极管[3]、太阳能电池[4-5]、聚合物[6]等领域。然而,数据的缺乏却严重限制了其发展。现有的材料数据库大多是计算属性数据库,基于实验的结构化数据库仍然缺乏。例如 materials project 数据库包含了超过 13 万条无机化合物的计算信息,而类似的实验数据仅有 9 千条[7]。因此,建立完善的材料数据库对新材料研发具有重要的意义。

近十年来,互联网和 Web 的加速发展促进了信息共享和数据交换。这种趋势在科学论文数量的快速增长上也得到体现[8]。通过对 web of science 数据库上的论文分析,发现自 20 世纪 90 年代末,材料科学的论文数量呈指数增长趋势。论文里包含大量不同材料的合成、性能及表征数据,从大量不断增长的材料科学文献中获取信息,建立实验合成性能数据库具有非常大的潜力。然而,文献里面的数据呈现非结构化的形式,因研究人员撰写文章的方式多样化,并选择最突出的研究结果来表达他们的科学观点。其次,数据分散于文本、图形或表格之中。例如,研究人员可能会在表格里展示一种合金的成分,在正文中的方法部分展示合金的加工条件,最后在结果中展示合金的性能。因此,从大量文献中提取数据是一个复杂而且耗时的过程,需要大量的人力和时间。为了有效地处理这些数据,需要一种自动化的方法来提取和整合材料科学文献中的数据。近几年自然语言处理(Natural Language Processing, NLP)等技术的迅速发展,使得大规模自动化提取数据成为可能。

NLP 的发展经历了由知识驱动到数据驱动的转变。上世纪中叶,研究人员在语言理论的基础上,取得了许多研究成果:自动生成文章摘要[9]、正则表达式编译器[10]等。然而,单一语言理论并不能满足复杂的现实需求。20 世纪 90 年代,技术的进步允许存储大量的数据,NLP 逐步转变为数据驱动,利用统计方法和机器学习算法,从大规模的语料库中学习语言规律和模式。这种方法提高了 NLP 系统的鲁棒性和泛化能力,但也面临着数据稀疏、特征工程等问题[11]。21 世纪初,深度学习技术的兴起为 NLP 带来了新的机遇。深度学习模型可以自动从原始数据中提取高层次的特征,并处理多种类型的输入和输出。

最近,基于神经网络的预训练模型(如 BERT[12]、GPT[13]等)在各种 NLP 任务上取得了令人惊叹的效果。特别是像 ChatGPT 这样的大型预训练语言模型,其在自然语言理解和生成任务上的性能显著提高,为材料科学领域的文本挖掘和信息提取带来了巨大潜力。将信息提取的数据作为机器学习模型的输入,有望缩短材料的研发周期、降低研发成本(图 1)。

本文从介绍 NLP 信息提取的一般方法出发,分析其应用在材料科学领域的潜在挑战和应对策略,总结归纳 NLP 和图像识别在材料信息学中的研究进展及发展趋势。接着,介绍了大型预训练语言模型,特别是 ChatGPT 在材料科学中的应用前景。最后,信息提取作为材料研发的有利工具,结合最新的预训练模型,我们展望了未来可能的发展方向。

2 NLP 文献信息提取的框架和方法

在大多数自然语言处理(NLP)流程中,研究人员通常遵循以下 5 个主要步骤[14](如图 2 所示):1)文本语料库构建;2)文本预处理,将文本分割成最小的标记(token),并将词语时态还原;3)文档分割,筛选包含目标信息的段落或句子;4)命名实体识别

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

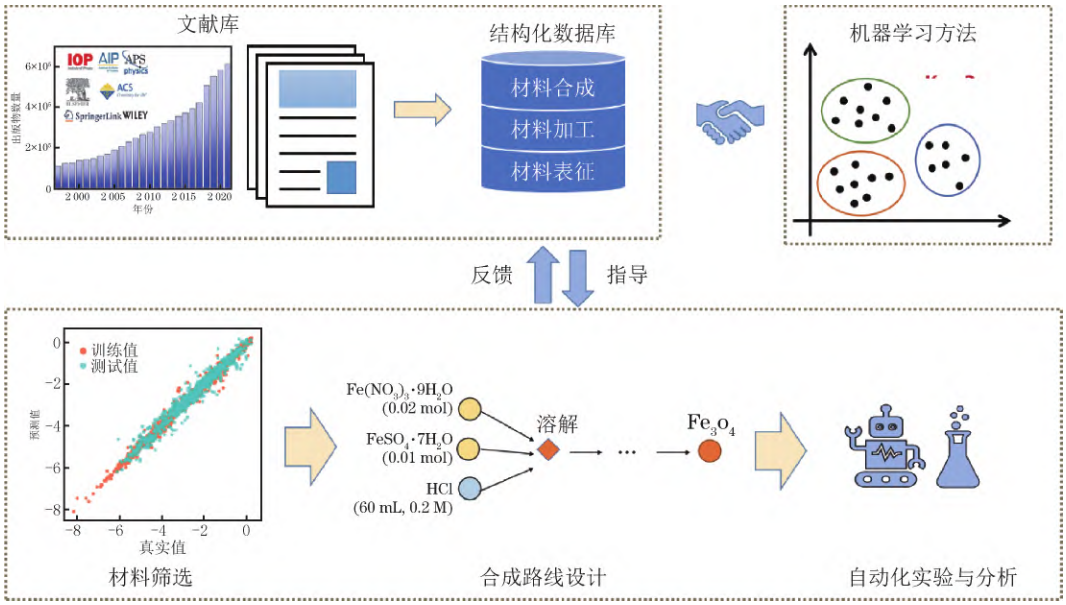

图 1　信息提取和机器学习的应用

Fig. 1　Applications of information extraction and machine learning

图 2　自然语言处理提取管道的一般流程

Fig. 2　Natural language processing extraction pipeline

(Named Entity Recognition，NER)，识别文本中的特定信息，如材料、前驱体、加热温度等；5)实体关系抽取，将多个实体通过不同的关系连接成一个整体。根据具体问题的需求，研究人员可能会选择应用上述流程的部分或全部方法。通过 NLP 提取的数据可以存储在数据库中，为后续的分析提供数据来源。接下来将详细介绍每个步骤，并讨论在材料科学领域的相关研究方法。

2.1　文本语料库构建和文本预处理

构建感兴趣主题的文本语料库是 NLP 的起始步骤。这些文本可以来自于期刊论文、专利和技术报告等。早期，PDF 格式作为主要的文本存储方式。但是由于 PDF 转换为纯文本可能存在误差，开发高精度的 PDF 解析器显得至关重要。随着出版物数量的增加，HTML 和 XML 已成为 NLP 任务中的优选文本格式，这些格式转换为纯文本时具有较高的一致性。获取 HTML、XML 和 PDF 的方法主要有两种：1)利用出版商提供的文本挖掘应用程序编程接口(API)；2)为不同出版商定制特定的网络爬虫。表 1 总结了化学和材料科学领域常用数据库的 API。通过使用 API，可以方便且快速地下载具有统一格式的论文。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

表 1 常用文本数据库的 API 接口

Table 1 API interface of common text repositories

数据库	文档类型	访问	链接
Science Direct (Elsevier)	全文	订阅	https://dev.elsevier.com/
Scopus (Elsevier)	摘要	公开	https://dev.elsevier.com/
Springer Nature	全文	订阅	https://dev.springernature.com/
Wiley	全文	订阅	https://onlinelibrary.wiley.com/library-info/resources/text-and-datamining
ACS	全文	订阅	https://solutions.acs.org/solutions/text-and-data-mining/
DOAJ	全文	公开	https://doaj.org/

在没有出版商提供 API 的情况下，网络爬虫成为唯一可行的选择。Kononova 等人[15]提供了针对 Elsevier、RSC、ECS 和 AIP 出版商的爬虫。类似地，ChemDataExtractor[16]也提供了针对 Elsevier、RSC 和 Springer 的爬虫。这些爬虫工具有助于从不同来源获取相关领域的文本资料，从而为 NLP 研究提供丰富的数据来源。

在获取语料库后，通常需要对文本进行预处理。分词(tokenization)是将文本分割成具有意义的标记，这有助于构建词汇表和生成文档向量。分词的准确性将直接影响最终结果的准确性。通用分词器，如 NLTK[17]和 Spacy[18]的分词效果在表 2 中进行了展示。然而，在材料科学领域，由于化学式和特殊符号的存在可能导致过度分割，例如 Pd(thd)2 可能被分为| Pd | (| thd |) | 2 |。因此，材料科学领域发展了一些专门针对化学的 NLP 工具包，如 ChemDataExtractor[16]、OSCAR4[19]和 ChemicalTagger[20]。这些化学 NLP 工具包在处理化学术语方面表现优异，但在处理文本其他部分时，精度可能相对较低。预处理工作还包括词形还原、词性标注(Part-of-Speech，POS)和依赖解析(dependency parsing)。这些方法通常用于减少整个文档的词汇量，并为命名实体识别和关系抽取任务提供单词的语法特征作为输入[21]。通过这些预处理步骤，可以有效地为后续的 NLP 任务提供清晰且有结构的文本数据，从而提高处理效果和准确性。

表 2 不同分词器的分词结果

Table 2 Tokenization of different word segmentation devices

Palladium oxide thin films were grown using Pd(thd)2.	
NLTK	Palladium | oxide | thin | films | were | grown | using | Pd | (| thd |) | 2 |
Spacy3	Palladium | oxide | thin | films | were | grown | using | Pd(thd) 2 |
ChemDataExtractor	Palladium | oxide | thin | films | were | grown | using | Pd(thd) 2 |

词向量嵌入(Word Embedding)模型通常用于将标记转换为向量形式，以便将其输入到模型中。这种模型为每个词语构建一个密集向量，并利用神经网络根据上下文自动调整向量值[22]。不同的词向量嵌入模型(如 GloVe[23]、word2vec[24]和 FastText[25])具有可调的向量维度，有助于减少计算量。

在材料科学领域，词向量嵌入模型被广泛应用于设计单词特征，这些特征通常被用作命名实体识别和关系抽取任务的输入[26-28]。例如，Huang 等[26]采用了一种基于多词检测和 word2vec 方法的策略，构建了多词化学术语的单词特征，准确地识别了来自 119,166 个化学专利的多词化学术语。与传统的单词识别方法相比，这种多词识别方法在保留化学短语语义方面表现得更为健壮和准确。Kim 等[28]使用 ElMo 和 FastText 词嵌入模型表示文本特征，并将其输入到命名实体识别模型中。接着，他们采用了无监督条件变分自编码器(CVAE)，生成了感兴趣无机材料的合成路径。Weston 等[27]运用 word2vec 词嵌入模型从 327 万篇摘要中提取了超过 8000 万个材料科学相关的实体，包括无机材料名称、合成和表征方法。通过将每个摘要的内容表示为结构化格式的数据库条目，实现了对材料科学领域的大规模知识抽取。

2.2 命名实体识别和关系抽取

传统的信息提取主要包括两个关键步骤：NER 和关系抽取。命名实体识别任务旨在将前述分词过程得到的一个或多个标记分类为不同的类别。关系

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

抽取则涉及从文本中抽取实体之间的关系。回顾历史，NER 已在医学领域取得初步成果，例如从文本中提取症状、诊断意见和药物信息[29]。在材料科学领域，NER 也已成功应用于识别无机材料性能[30-31]、聚合物[32]、纳米材料[33]以及合成路线[34]等实体。以下列举了一些 NER 的方法，包括基于规则的方法和机器学习的方法。

基于规则的方法通常通过设计正则表达式等规则来匹配实体。规则的制定需要对大量文本进行检查以提高适用性，同时也可借助领域内命名法。材料科学领域的现有 NER 工具包括 LeadMine[35]（使用命名约定规则）、ChemicalTagger[20]（解析实验合成部分）以及 ChemDataExtractor[16]（采用嵌套规则）等。基于规则的方法匹配精度高，但是规则的设计过程复杂且耗时。

机器学习方法通过学习词向量特征和上下文关系来识别特定实体。图 3(a)展示了常用于 NER 的神经网络模型，该模型将文本转换为词向量，通过双向长短时记忆网络(BiLSTM)和条件随机场(CRF)对每个标签进行概率估计。根据模型输出，第 1 和第 2 个标记表示前体实体，第 3 个标记表示温度实体。与基于规则的方法相比，机器学习方法无需制定繁琐规则且具有较强泛化能力。然而，监督模型通常需要大量专家注释的数据进行训练，训练效果可能不稳定。例如，Kim[36]等人标记了由 20 篇文章(约 5200 个单词)组成的训练集，利用人工标注的单词标签训练神经网络权重，取得了 81% 的 F1 分数。基于此，Kononova[15]等人手动标注了 750 篇论文中的 834 个固态合成段落，采用 LSTM 和 CRF 识别不同实体。识别准确率在加热条件、混合条件和材料方面，分别达到了 62% 至 99% 的不等。

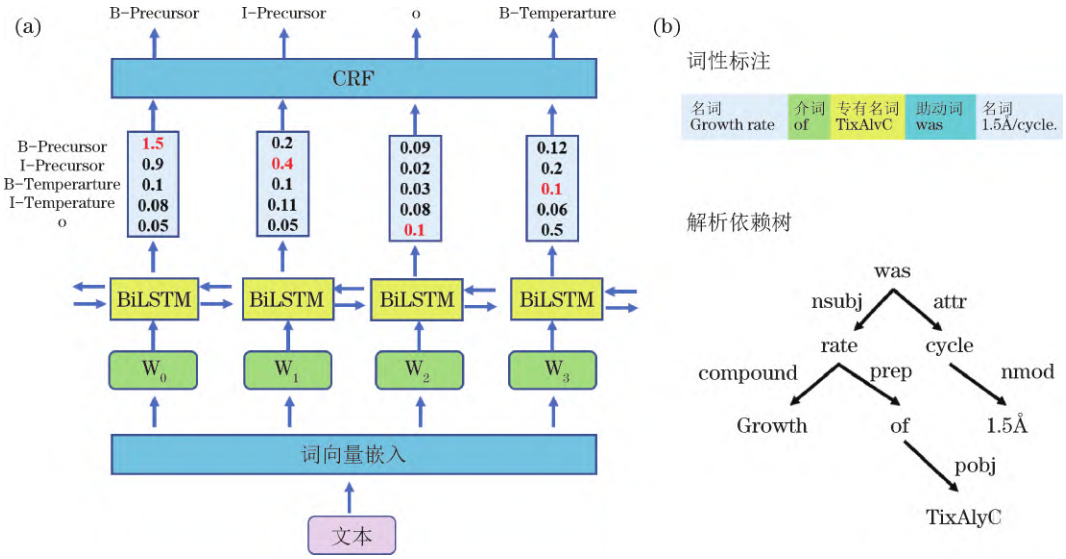

图 3　BiLSTM-CRF(a)和依赖解析(b)

Fig. 3　BiLSTM-CRF(a) and dependency parsing(b)

尽管已经付出巨大努力，化学 NER 模型在识别化学名称和公式方面的准确性仍相对较低[37-38]。通用 NER 模型的精度和召回率可达到 90% 以上，而化学 NER 有时仅能达到 60%[39]。化学高精度 NER 模型训练的主要障碍是缺乏特定领域内专家注释的高质量大型数据集。现有的公开可用标注数据集包括：NaDev 语料库(包含 392 个句子和 2 870 个纳米晶体器件开发术语)[40]；固态氧化物燃料电池数据集(含 9 499 个标注句子)[41]；无机合成数据集(包含 3 040 个句子)[42]；锂离子电池注释数据集(含 6 985 个段落)[43]。此外，化学 NER 通常仅适用于特定领域的命名实体识别，难以有效处理跨领域情况。例如，在聚合物命名实体识别(polyNER)任务中，Tchoua 等人使用自定义训练集训练 polyNER 模型[32]。由于合成聚合物通常不是单一实体，而是通过分子量分布描述，因此需对聚合物进行预处理。这导致特定领域训练的 NER 模型在不同材料间无法通用。

关系抽取旨在提取不同实体间的语义关系。在材料科学领域，大多数实体关系抽取是通过依赖解

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

析实现的，它通过分析句子的语法结构来构建解析依赖树。如图 3(b)所示，根据语法和词性，可以构建不同词语之间的依赖关系。遍历整个依赖树可以得到 TixAlyC 的生长速度为 0.15 nm/cycle。目前，材料科学领域也有一些相关的语法解析工具包可供使用。例如，ChemicalTagger[20]提供了化学文本的语法解析工具，以找到实体与相应动作动词之间的关系。同样地，ChemDataExtractor[16]可以识别文本中的化学和物理特性(如熔点)，并将其分配给一个材料实体。此外，一些先进的神经网络也被应用于关系抽取任务。Onishi 等[44]使用卷积神经网络模型从出版物中提取材料、力学性能和加工条件之间的关系。最近，Kuniyoshi 等[45]和 Mysore 等[46]采用了先进的 NLP 模型组合，用于提取材料合成步骤，并将其应用于固态电池材料和一般无机材料的合成过程。然而，目前的关系抽取技术主要集中在小范围内的实体关系，如段落内的关系抽取。针对长距离和多元关系组等复杂场景，这些技术仍存在局限性。

2.3 Transformer 架构的预训练模型

传统的 NLP 方法通常需要为不同任务构建独立的模型，并且需要大量标注数据以获得良好的性能。近年来，基于 Transformer 架构的大型预训练语言模型和微调技术在自然语言处理领域取得了显著的进展。这些模型首先在大量无标注文本数据上进行预训练，然后在特定任务的较小标注数据集上进行微调。这种预训练和微调的方法已经在许多 NLP 任务中取得了比传统方法更优异的表现。

Transformer[47]模型由 6 个编码器和 6 个解码器组成。图 4(a)展示了一个编码器和一个解码器的结构。编码器包含自注意力层(Self-Attention)和前馈神经网络层。自注意力机制是 Transformer 模型与传统 NLP 模型最显著的区别。当词向量输入到自注意力层时，模型会计算当前位置与其他位置的注意力权重，以捕捉输入序列中不同位置之间的关系。例如，当 Pd(thd)2 输入到模型时，模型计算的 Palladium 和 oxide 的注意力权重较高，因此这两个词对于 Pd(thd)2 较为重要(图 4(b))。计算每个位置的注意力权重是独立的，因此 Transformer 可以并行处理整个序列中的所有位置，使其在处理长序列时具有非常高的效率。Transformer 还进一步优化了自注意力层，引入了多头注意力机制(Multi-Headed Self-Attention)，可以同时关注输入序列的不同方面，从而更好地捕捉输入序列中的信息。此外，为了处理序列中位置信息的问题，Transformer 在输入的词向量中添加了位置嵌入(Position-Embedding)，通过将位置向量与词向量相加的方式，使模型能够区分不同位置的词向量表示。这样，模型就可以同时考虑输入序列中不同位置的信息，并捕捉它们之间的关系。

基于 Transformer 架构的两个主要模型分别是 BERT 和 GPT。BERT[12]采用了多层编码器堆叠的结构。BERT 架构是双向的，这允许它从特定单词中学习上下文。BERT 的预训练过程包括两个主要任务：遮蔽语言建模(Masked Language Modeling，MLM)和下一句预测(Next Sentence Prediction，NSP)。MLM 类似于完形填空，模型需预测给定句子中被遮蔽的单词。NSP 旨在判断句子对之间的逻辑关系，模型需预测它们是否连续。因此，BERT 在文本理解能力上表现更优，适用于各种下游任务。

目前，已开发出针对不同领域的 BERT 模型，取得显著成果。例如，BioBERT[48]针对生物科学语料库，SciBERT[49]针对科学和生物语料库，clinicalBERT[50]针对医学临床，mBERT[51]针对多语言机器翻译，PatentBERT[52]针对专利分类，FinBERT[53]针对金融领域。在材料学领域，Gupta[54]等提出了预训练模型 MatSciBERT。训练数据包括约 15 万篇涵盖无机玻璃、金属玻璃、合金、陶瓷等材料学文献，以及纳米材料、聚合物和生物材料等相关文献。这些文献覆盖了实验和计算方法，对理解物质反应至关重要。MatSciBERT 在预训练 SciBERT 上进一步预训练。相较于 BERT 和 SciBERT，MatSciBERT 在材料学领域的命名实体识别、关系抽取和摘要分类 3 个下游任务中表现最佳。这表明在通用模型基础上进行特定领域训练可能带来更好表现。另外，Zhao[55]等人提出了两个光学领域的预训练模型：针对文本的 OpticalBERT 和针对表格的 OpticalTable-SQA。结果显示，微调这两个模型在光学材料的各种文本挖掘任务上优于 BERT 和之前的最先进模型。

GPT[13]采用多层解码器堆叠的结构。与 BERT 不同，GPT 是一个单向模型，通过前面输入的句子预测下一个最有可能出现的单词。它仅考虑输入序列中前面的上下文信息，而不考虑后面的信息。因此，GPT 主要应用于生成型任务，如文本生

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

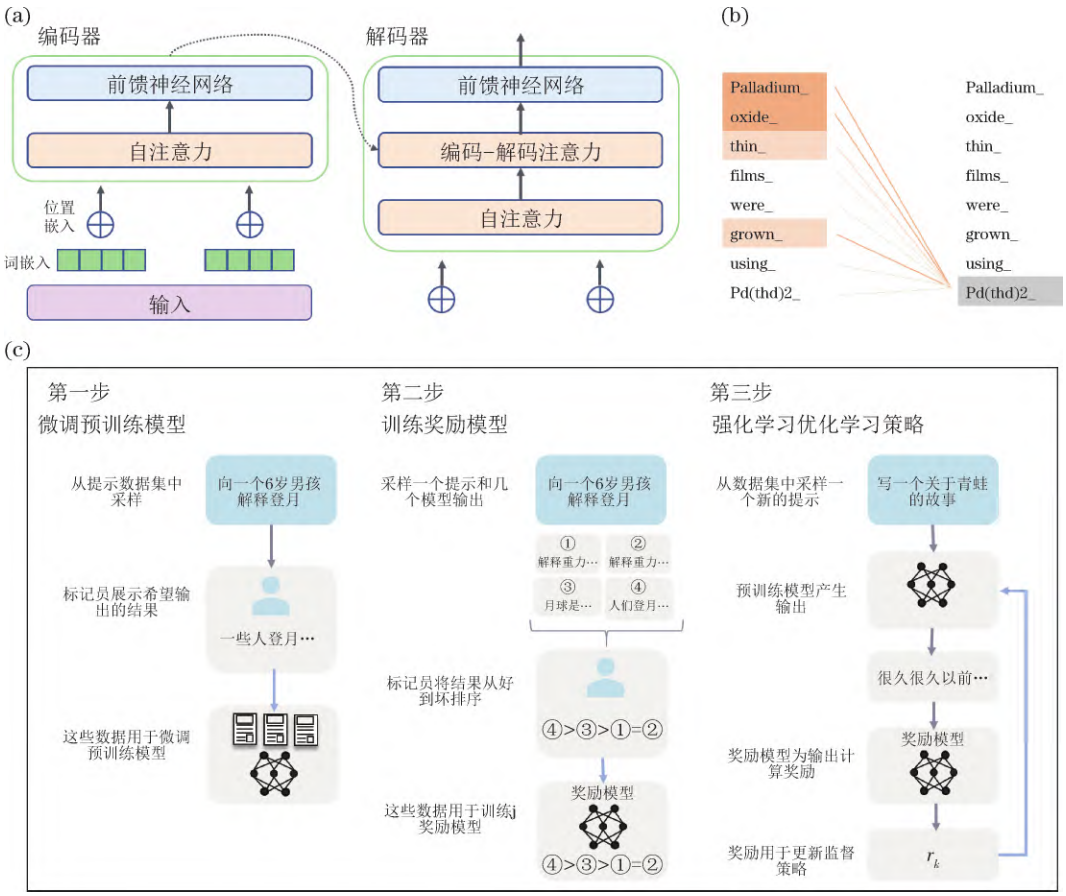

图 4　Transformer 基本结构(a)、自注意力机制(b)、人类反馈的强化学习方案(c)[48]

Fig. 4　Transformer basic structure(a), self-attention(b) and reinforcement learning from human feedback(c)[48]

成和机器翻译等。从 GPT-1[13] 到 GPT-3[56],参数从 1.5 亿增加到 1 750 亿。随着模型规模和参数数量的增加,GPT 模型在生成文本的质量、多样性、连贯性等方面得到显著提升。然而,模型规模的增加可能导致生成不真实、对用户无帮助的输出。InstructGPT[57] 基于 GPT-3,采用了人类反馈的强化学习方案(Reinforcement Learning from Human Feedback,RLHF)。RLHF 的流程如图 4(c)所示,分为 3 个步骤:1)让监督策略从标注员的问题回答中学习;2)训练奖励模型,标注员从监督策略生成的多个回答中选择最佳回答并进行排序;3)使用奖励模型评估监督策略模型的回答,不停迭代,以指导模型生成更好的回答。因此,InstructGPT 能更好地理解人类思维,生成人类想要的答案。ChatGPT 则在 InstructGPT 基础上增加了对话的功能。

模型性能与参数数量、训练数据量大小以及计算量呈指数关系[58]。大型语言模型和微调方法使传统信息提取方法逐步淘汰。大型语言模型有望在材料科学领域的自动化文献分析方面发挥重要作用。

2.4　从图像和表格中提取信息

除了从文本中提取信息外,文档中嵌入的图表也包含着有价值的数据。这些图表可以提供一种直观的方式来呈现数据,使得读者可以更容易地理解和比较数据,发现趋势和模式。

图像分割算法在显微镜图像上的应用显示出了巨大潜力,极大地提高了晶界分割、颗粒检测和计数技术,有利于材料微观结构的识别和形态研究。在冶金领域,Decost[59] 等人使用卷积神经网络(CNN)分析超高碳钢的扫描电子显微镜(SEM)图像中的晶界信息(如图 5(a)所示,引用自[59],版权归 Oxford University Press 所有)。Azimi 和 Gola 等人利用 CNN[60] 和支持向量机[61](SVM)对钢材的微观结构特征进行分类。在纳米材料领域,Kim[62] 等人使用 Google Inception-V3 网络[63] 创建了 Livermore SEM Image Tools,用于识别纳米粒子的大

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

小，并将纳米粒子的形态分为四类：纳米立方体、纳米颗粒、核壳结构和纳米棒（如图 5(b)所示，引用自[62]，版权归 RSC 所有）。Hiszpanski[33] 等随后将该工具应用于约 35,000 篇论文，以获得有关纳米颗粒大小和形态的信息。最近，Jung[64] 等采用了卷积神经网络自动识别红外光谱中分子的官能团，而不需要繁琐的数据库搜索（如图 5(c)所示，引用自[64]，版权归 RSC 所有）。此外，一些研究者开发了从文档中提取和量化显微图像的工具。Mukaddem[65] 等开发了 ImageDataExtractor 工具，该工具使用 OCR 和 CNN 的组合从显微镜图像中提取粒子的大小和形状。另一种图像识别工具为化学分子结构识别，包括 ChemReader[66]、OSRA[67] 和 ChemSchematicResolver[68]（如图 5(d)所示，引用自[68]，版权归 ACS 所有）。这些工具的操作流程是将化学结构图像分割成结构和文本，并将其转化为键和原子的形式。

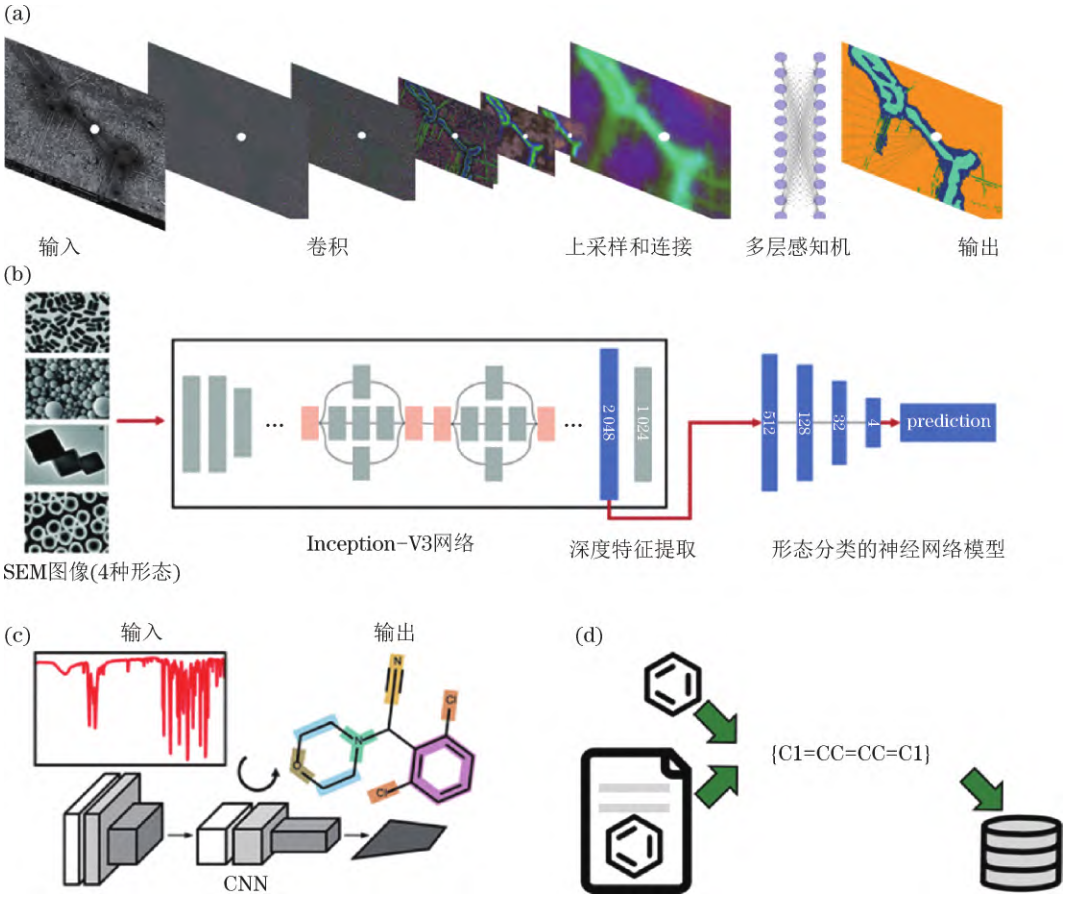

(a) CNN 提取晶界信息[59]；(b) Inception-V3 识别纳米颗粒形态[62]；(c) CNN 识别红外光谱中分子的官能团[64]；(d) 识别化学分子结构[68]。

图 5 图像识别在材料科学中的应用

Fig. 5 Application of image recognition in materials science

表格以规范的格式存储了大量的信息，一些研究者也开发了表格分析工具以更好地利用这些数据。例如，TableDataExtractor[69] 能够将复杂的表格结构标准化，将原始表格分解成不同的数据区域，如复杂的嵌套行/列标题、子表格、跨列单元格、标题、注释单元格和脚注等。这使得数据可以更加清晰、易于理解和处理。另外，有些工具如 Tapas[70] 和 T3QA[71] 能够通过自然语言处理的方式回答与表格相关的问题。这种方法可以让用户更直观地查询表格数据，从而提高数据的可用性和可操作性。这些工具的开发为研究人员提供了更有效的方式来利用表格数据，有助于进一步推动材料科学等领域的研究进展。

3 NLP 驱动的材料研发实例

3.1 公共开放的材料数据库构建

在采用 NLP 技术自动提取信息之前，许多大规模的数据库都是通过人工手动建立和维护的。尽管

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

手动构建这些大型数据库耗费了大量的时间和精力，但这些数据库具有高准确性，并且信息来源广泛，涵盖了文本、表格和图形等各种形式。因此，对这些数据库进行详细列举是有意义的。

Pauling File Project[72]是最大的无机晶体数据库之一，覆盖了晶体学数据、物理性质和相图。该数据库包含了超过 35 万个晶体结构、15 万个物理性质，以及从材料科学、工程学、物理学和无机化学等领域文献中提取的 5 万个相图。这些数据具有非常高的质量和准确性，还包括了专家注释和原始文本摘要。然而，这些数据的结构不一致，需要进行额外的处理和规范化。Dark Reactions Project[73]是另一个著名的手动提取数据集。它包括了从实验期刊中提取的 3 955 个失败的水热合成实验参数。在机器学习领域，负样本数据对模型的训练同样非常重要。然而，失败的实验合成参数很少被发表。Dark Reactions Project 首次强调了在化学和材料科学领域分享失败结果数据的重要性。这种实践不仅有助于研究者避免重复错误，还有助于提高实验和模型的准确性。

Cole 的研究团队在自动提取材料属性信息方面取得了很大成果。他们开发了 ChemDataExtractor 工具，创建了磁性材料相变温度数据库[74]和电池材料电化学性能数据库[75]。第一个数据库包含了从 68，078 篇研究文章中检索的 39，822 条居里温度和 Néel 温度数据。这些数据描述了铁磁相变和反铁磁相变的温度。这些数据扩充了 MAGNDATA 数据库，这是一个由 Gallego[76]等从研究文章中手动提取的 1 000 个磁性结构数据集。第二个数据库包含了从 229，061 篇文章中提取的 29，313 条数据，涉及电池材料的电化学性能，包括电池容量、电压、电导率、库伦效率和能力密度等。这个数据库扩充了由 Ghadeigi[77]等人手动创建的，包含了来自 200 多篇研究文章的 16 000 条锂离子电池材料属性数据。

Ceder 的研究团队在过去几年中成功自动化收集了大量材料合成数据。Kim[36]等人从 64 万篇文献中自动化收集了 30 种不同金属氧化物的合成路线。此外，Kononova[15]等人从 53，538 篇材料文献中自动获取了 19 488 个固态陶瓷合成反应，包括所使用的前驱体、合成路线和性能。最近，Wang[78]等人利用先进的机器学习和自然语言处理技术从科学文献中提取了基于溶液的无机材料合成数据，包括目标材料、前体及其数量、合成操作及其属性等信息。然后，他们使用这些信息为每个合成过程建立了反应式。这个数据集是第一个大规模的基于溶液的合成数据集，为测试和验证现有的经验合成规则、提高预测准确性，甚至挖掘指导合成的新规则提供了基础。

表 3　手动提取和文本挖掘的数据集

Table 3　Data sets for manual extraction and text mining

数据集名	内容	类别
Pauling File Project	晶体学数据、物理性质和相图	手动
Dark Reactions Project	3 955 个失败的水热合成实验参数集	手动
磁性材料相转变温度数据库	39 822 条居里温度和 Néel 温度	自动
电池材料电化学性能数据库	29 313 条数据，涉及电池材料的电化学性能，包括电池容量、电压、电导率、库伦效率和能量密度等	自动
金属氧化物的合成数据库	30 种不同金属氧化物的合成路线	自动
固态陶瓷合成数据库	19 488 条固态陶瓷合成路线	自动
溶液无机材料合成数据库	35 678 条基于溶液的无机材料合成路线	自动

3.2　基于文献数据库的材料设计

数据可视化有助于研究人员更好地认识数据中的规律。例如，Hiszpanski[33]等提供了一个金属纳米材料合成数据库，并用可视化工具展示了纳米材料合成路线和最终形态，发现某些试剂与特定纳米材料形态和成分之间存在一定的相关性。Young[79]等将脉冲激光沉积工艺数据的生长窗口、趋势和异常值可视化，为分析生长条件的分布提供了初步的途径，并与第一性原理计算相结合，以便更好地关联热力学稳定窗口。在金属氧化物合成数据集中，Kim[80]等通过可视化不同元素和煅烧温度，发现合成元素种类更多的块状材料时，通常需要更高的煅烧温度。Kononova[15]等在固态合成数据集中，可视化了不同化学元素和典型的离子共存情况，获得了固态合成的见解。Cruse[81]等构建了一个金纳米颗粒合成数据集，并利用数据可视化的方式展示了不同前体在合成金纳米颗粒时所使用的频率以及目标形态（如图 6(a)所示，引用自[81]，版权归

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

Springer Nature 所有)。他们发现,某些物质在纳米棒合成的文献中出现频率较高,而其他物质则在特定纳米结构的制备中被广泛应用。进一步挖掘数据中的潜在信息,可以利用机器学习等方法。Court 和 Cole[82]利用磁性材料相转变温度数据集,通过岭回归、支持向量回归等机器学习模型,重构磁性和超导相图,并预测了稀土锰酸盐的 Néel 温度和镧系的超导临界温度 T_c,展示了预测材料性能的潜力。Zhang[83]等使用 ChemDataExtractor 收集了大量折射率数据,利用机器学习重建已知光学材料的色散关系,并开发了一个预测折射率的机器学习平台。Wang[1]等从大量文章中提取了合金成分和性能数据,建立了熔化温度的数据驱动模型,实现了相对误差为 0.81% 的预测(如图 6(b)(c)所示,引用自[1],版权归 Springer Nature 所有)。

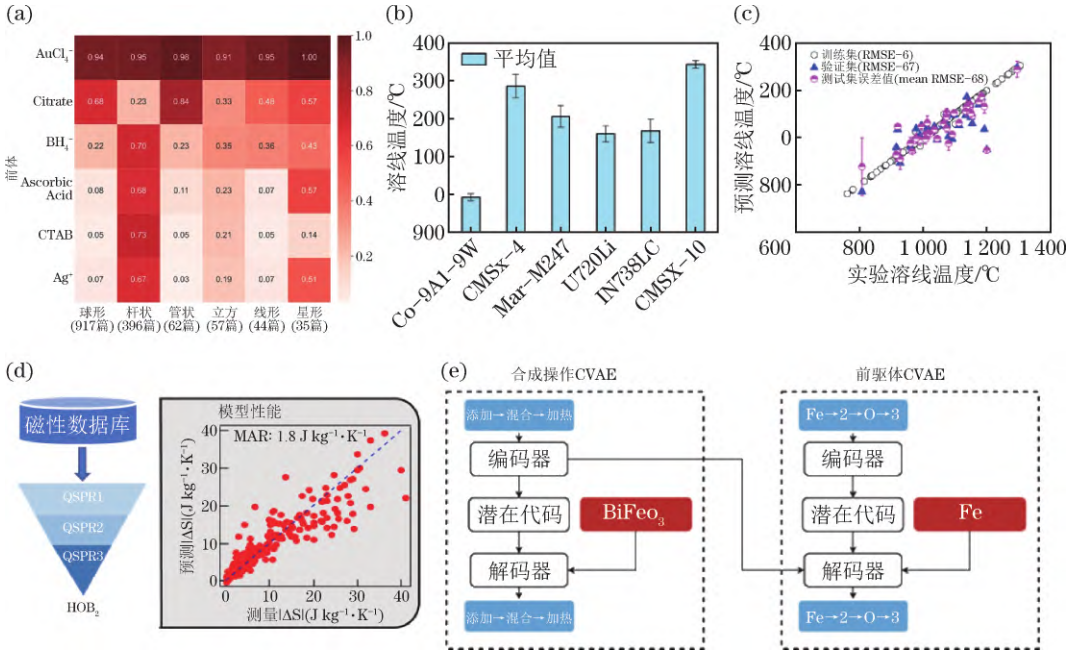

(a) 描述前体与最终 AuNP 形态之间相关性的热图[81];(b)(c) 合金溶线温度的预测[1];
(d) 磁性制冷材料的筛选[85];(e) 钙钛矿材料的逆向设计[28]。

图 6 数据驱动的几种方式

Fig. 6 Several data-driven approaches

另一种应用机器学习方法的途径是基于定量结构-性质关系(QSPRs)。这种方法在小规模数据库上已经存在了很长时间,如今正应用于分析大量数据的多个结构-性质关系。例如,可以通过一系列递进的问题筛选数据集,如"哪些数据符合这个 QSPR?"这些问题构成了一个逆金字塔形式的决策流程。逐步筛选数据,选出符合特定应用需求的候选材料,然后通过实验验证。在紫外/可见吸收光谱特性数据库[84]中,通过 QSPRs 分层决策流程成功地筛选出 5 种适用于光伏应用的光收集材料。利用 NLP 生成的磁性材料数据库,Kim[85]等在机器学习方法指导下成功合成了一种新型磁性制冷剂 HoB_2。该物质在二级铁磁相变处表现出 40.1 J kg^{-1} K^{-1}的巨大磁熵变,这是当时报道的最高值(如图 6(d)所示,引用自[85],版权归 Springer 所有)。通过分析 NLP 提取的结构化数据,还可以得到有意义且易于理解的材料见解。例如,Kim 等人利用决策树模型研究水热法合成钛酸盐纳米管所需的关键参数,发现 NaOH 和温度是主要控制因素,这与已知机制有所不同[85]。此外,这项工作还展示了迁移学习的能力,预测了 $BiFeO_3$ 的相(在 $BaTiO_3$ 上训练),将合成向量输入到支持向量机的性能比将退火温度输入到启发式逻辑回归高出 40%。

未来的知识在很大程度上隐藏在过去的文献中。例如,Tshitoyan 等[86]使用 word2vec 模型对 300 万个摘要进行矢量化表示学习,专注于单词和材料。该模型不仅学习材料间的化学联系,还能比较不同应用领域的材料相似性。这项研究证明了跨领域相关性可用于预测新型热电材料。这强调了科学技术和自然语言处理的重要性:通过理解大量非

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

结构化数据来揭示潜在知识，这是人类无法完成的任务。更复杂的机器学习模型如生成神经网络也应用于材料设计。这些模型学习有机分子的潜在表示，并在潜在空间中探索以生成新分子。例如，Kim 等[87]基于文献观察到的合成参数，采用生成式机器学习模型生成 $SrTiO_3$ 可能的合成参数集，并发现与板钛矿 TiO_2 和 MnO_2 多晶体相关的驱动因素。他们还将此方法应用于钙钛矿材料的合成[28]（如图 6(e)所示，引用自[28]，版权归 ACS 所有）。他们利用无监督变分自编码器（CVAE）生成了 $InWO_3$ 和 $PbMoO_3$ 的前驱体，然而这些前驱体直到 2016 年和 2017 年才首次发表，没有包含在训练数据中。这表明，生成式机器学习模型具有学习材料相关性质的能力，可用于预测新材料的合成。最近，Jensen 等[88]利用 NLP 技术从科学文献中提取有机结构导向剂（OSDA）和沸石相数据，采用生成式神经网络为给定沸石结构和凝胶化学提出新的潜在 OSDA 分子。另外，一些可解释方法也被运用以弥补先进机器学习模型的可解释性不足。例如，Karpovich 等[89]使用 CAVE 生成特定固态反应的合成条件，并用 SHAP 方法解释模型预测以验证常见合成趋势并获得合成见解。

3.3　大语言模型应用于 ALD 工艺数据库建立

原子层沉积（Atomic Layer Deposition，ALD）是一种在材料表面逐层生长单原子或分子薄膜的技术。近年来，随着 ALD 技术在纳米电子学、储能材料等领域的广泛应用，研究 ALD 工艺参数变得越来越重要。华中科技大学微纳材料设计与制造研究中心在 ALD 实验和计算方面开展了一系列原创性工作[90-98]：在实验方面，发展了内禀选择性 ALD 方法实现催化剂结构精细调控和性能提升[92]，包括制备铂单原子嵌入钴纳米团簇的高分散催化剂，应用于一氧化碳在氢气氛围中氧化活性和选择性的同时提升[93]；发展晶面选择性沉积方法制备包覆构型并探索了铂纳米颗粒气化迁移的稳定化机制[94]；发展了镍纳米颗粒表面网格状包覆构型，通过分隔纳米颗粒表面提升对甲烷二氧化碳重整反应的积碳抵抗性[95]。在计算方面，首次运用跨尺度模拟方法从理论上揭示了 MCp2[96]（M＝Fe，Co，Ni）和 DMAI[97]前驱体在不同铂晶面上的选择性生长；通过第一性原理和反应动力学，揭示了 MnO_x 在 Pt 上选择性生长的配体效应和基底效应[98]。为了更好地理解 ALD 工艺性能和优化薄膜生长，尝试将 NLP 应用于 ALD 文献的工艺数据挖掘和信息提取。

预训练模型加微调是一种非常有效的方法，可以使得模型在小数据集上也能达到高精度。利用 matBERT[99]预训练模型构建了一个 ALD 工艺性能数据库。通过使用 Elsevier 文本挖掘的 API，我们获取了 9 031 篇关于 ALD 的文献，其中涉及生长速率等信息的段落超过 2 000 个。为了微调模型，我们手动标注了 200 个段落，并设计了 10 个不同的标签（图 7(a)）。训练和测试数据集的比例为 3∶1，并使用 Spacy3 自然语言处理工具进行模型的训练和测试。我们观察到，测试结果显示不同标签的 F1 得分在 0.36 到 0.91 之间（图 7(b)）。其中，得分较低的标签可能是由于训练标签数量过少，导致模型未能充分学习到潜在规律。在完成实体识别任务之后，我们制定了一系列规则来抽取不同实体之间的关系。最终，成功地从文本中抽取出了 2 201 条信息，包括生长材料、前驱体和共反应物、生长温度和速率等方面的信息。通过对实验结果的分析，发现沉积氧化铝的温度较为广泛地分布在 135 ℃到 250 ℃之间。氧化铝最低的生长温度为 27 ℃，是在使用三甲基铝和 O_2 等离子体对 SiC 颗粒表面进行氧化铝薄膜包覆时实现的[100]。随着时间的推移，生长氧化铝的温度也不断降低，到 2022 年时生长温度已经降至 200 ℃以下。另外，氧化铝的生长速率主要分布在 0.065 nm/cycle 到 0.16 nm/cycle 之间。最大生长速率为 0.75 nm/cycle，是在使用三甲基铝和臭氧在 350 ℃的 Si 基底上得到的[101]。

最近 ChatGPT 在语义理解和语言生成方面表现优异，这为材料信息提取提供了一个新的思路。ChatGPT 的使用方式多样化，用户可以通过网页以对话的方式进行，也可以调用官方 API 进行交互。为了提高模型的性能和适用性，提示（prompt）技术被应用于 ChatGPT 模型微调中。提示技术的核心思想是通过向模型提供一些文本片段，来引导模型生成特定的输出，从而指导模型的微调。与 fine-tuning 技术相比，提示是一种更高级的形式，可以更好地控制模型的输出。

首先让 GPT 扮演了材料学领域的专家角色，并设定了一些输出规则，例如优先输出化学式而非名称。接下来，提供了一个示例，以便模型能够更好地学习。这个示例包括输入文本和期望的输出结果。最后，将未知结果的文本输入到模型中，并获得了 ChatGPT 返回的结果。表 4 展示了在同一个段

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

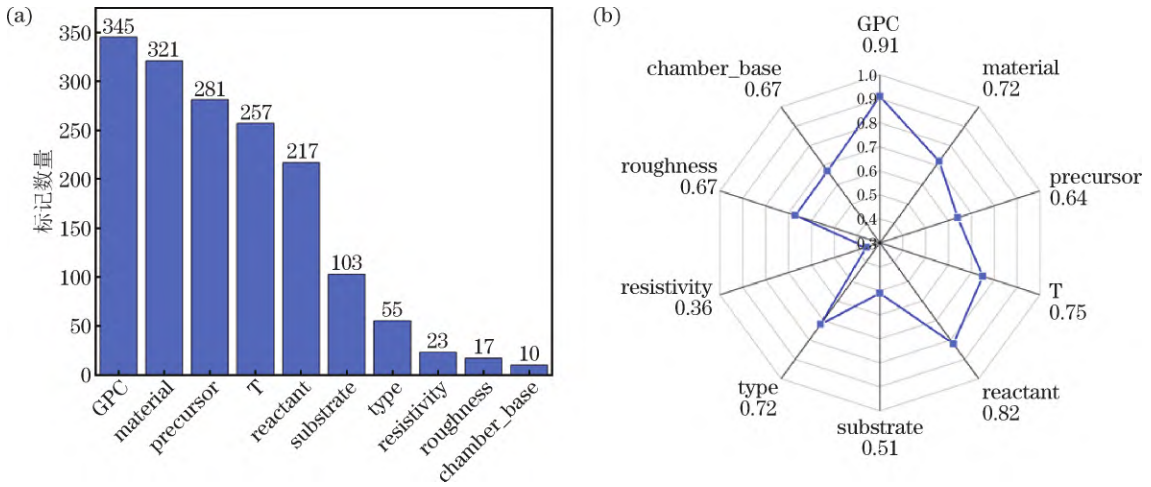

(a)各个标签的数量;(b) 各个标签的 F1 得分。

图 7 微调 BERT 模型的标签及精度

Fig. 7 Labels and precision of the fine-tuned BERT model

落中,使用微调过的 matBERT 和 ChatGPT 提取的结果。与原始文本相比,ChatGPT 还能正确提取基底,性能优于 matBERT。此外,使用提示所需的样本量较少,并且在添加新信息时更为简便。例如,若需添加薄膜电阻率等信息,只需修改提示,而无需标注大量电阻率标签。

我们的提示如下:

1. Now you are an expert in the field of materials science, you will help me dig for information in the literature

2. You should observe the following rules:

(1)try to output the chemical formula;

(2)try to use abbreviations;

3. example

表 4 微调 MatBERT 和 ChatGPT 结果对比

Table 4 Comparison of fine tuning MatBERT and ChatGPT

	生长材料	前驱体	共反应物	生长温度	基底	生长速率(GPC)/(nm·cycle^{-1})
微调 MatBERT	ZnO	Diethylzinc	Water	200 ℃	None	0.02
	TiO_2	$TiCl_4$	H_2O	200 ℃	None	0.07
ChatGPT	ZnO	Diethylzinc	Water	200 ℃	Si	0.02
	TiO_2	$TiCl_4$	H_2O	200 ℃	ZnO/Si	0.07

近期,GPT-4.0 还提供了多模态输入,不仅可以输入文本,还可以输入图片,这为文献中表格和图像信息提取提供了机会。结合机器学习和深度学习方法,有助于发现更多有趣的结论。但是值得注意的是,在使用 ChatGPT 过程中,我们发现它可能会虚构一些根本不存在的文献。因此在使用过程中,核实信息的真实性仍然十分重要。尽管通用的大语言模型已经展现了非常令人惊喜的能力,但是材料领域有其独特的术语和语言规则,使用专门训练的大型语言模型可以更好地处理领域内的问题。然而,训练一个大语言模型需要大量的数据和计算资源,需要评估需求和资源是否足够支持训练这样的模型。

4 总结与展望

随着出版物数量的持续增长,从这些出版物中自动化提取信息具有巨大的研究和应用价值。本文回顾了材料学领域中,NLP 和图表识别的常见流程、相关方法和工具,分析了 NLP 信息提取流程中存在的普适性差、精度不高等问题。接着介绍了最先进的 NLP 方法——微调大语言模型。总结归纳了 NLP 在材料学中的研究进展和发展趋势。最后,展望了大语言模型在材料学的未来应用。结合信息提取和机器学习在材料学中的应用,该领域的发展

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

趋势和面临的挑战如下：

(1)大语言模型将成为信息提取重要的发展方向。ChatGPT 在通用领域表现了非常出色的能力。未来训练材料学的大模型可能有助于加速材料研究和开发的进程。新发布的 GPT-4.0 展示了识别图像的能力，文本和图像等多种形式的输入分析将是大模型的重要发展方向。但是训练特定领域的大模型需要大量的数据及专家注释，建立统一的注释标准和收集高质量数据将是一个不小的挑战。

(2)实验数据和计算数据在材料信息学领域具有巨大的协同作用。科学文献并非机器学习模型所依赖的唯一数据来源。高通量实验和计算数据仍然是为模型提供最重要和高质量数据的来源。而从文献中提取的信息则为这些数据提供了有益的补充。然而，文献可能存在偏见，缺乏实验失败的数据。实验数据和计算数据的结合具有极大潜力。一方面，可以利用给定的计算数据判断提取的实验数据是否准确。另一方面，实验值和计算值的正确匹配可以确保计算数据的可靠性。最后，计算数据可以弥补实验数据中存在的数据缺失问题。

参考文献：

[1] WANG W R, JIANG X, TIAN S H, et al. Automated pipeline for superalloy data by text mining[J]. Npj Computational Materials, 2022, 8: 9.

[2] OLIYNYK A O, ANTONO E, SPARKS T D, et al. High-throughput machine-learning-driven synthesis of full-heusler compounds[J]. Chemistry of Materials, 2016, 28(20): 7324.

[3] GÓMEZ-BOMBARELLI R, AGUILERA-IPARRAGUIRRE J, HIRZEL T D, et al. Design of efficient molecular organic light-emitting diodes by a high-throughput virtual screening and experimental approach[J]. Nature Materials, 2016, 15(10): 1120.

[4] COOPER C B, BEARD E J, VÁZQUEZ-MAYAGOITIA Á, et al. Design-to-device approach affords panchromatic Co-sensitized solar cells[J]. Advanced Energy Materials, 2019, 9(5): 1802820.

[5] COLE J M, LOW K S, OZOE H, et al. Data mining with molecular design rules identifies new class of dyes for dye-sensitised solar cells[J]. Physical Chemistry Chemical Physics: PCCP, 2014, 16(48): 26684.

[6] MANNODI-KANAKKITHODI A, PILANIA G, HUAN T D, et al. Machine learning strategy for accelerated design of polymer dielectrics[J]. Scientific Reports, 2016, 6(1): 1.

[7] JAIN A, ONG S P, HAUTIER G, et al. Commentary: The Materials Project: a materials genome approach to accelerating materials innovation[J]. APL Materials, 2013, 1(1): 011002.

[8] BORNMANN L, MUTZ R. Growth rates of modern science: a bibliometric analysis based on the number of publications and cited references[J]. Journal of the Association for Information Science and Technology, 2015, 66(11): 2215.

[9] LUHN H P. The automatic creation of literature abstracts[J]. IBM Journal of Research and Development, 1958, 2(2): 159.

[10] THOMPSON K. Programming Techniques: regular expression search algorithm[J]. Communications of the ACM, 1968, 11(6): 419.

[11] QIU X P, SUN T X, XU Y G, et al. Pre-trained models for natural language processing: a survey[J]. Science China Technological Sciences, 2020, 63(10): 1872.

[12] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[EB/OL]. 2018: arXiv: 1810.04805. https://arxiv.org/abs/1810.04805

[13] RADFORD A, NARASIMHAN K. Improving language understanding by generative pre-training[C]// Montréal CANADA: Computer Science, 2018.

[14] OLIVETTI E A, COLE J M, KIM E, et al. Data-driven materials research enabled by natural language processing and information extraction[J]. Applied Physics Reviews, 2020, 7(4): 041317.

[15] KONONOVA O, HUO H Y, HE T J, et al. Text-mined dataset of inorganic materials synthesis recipes[J]. Scientific Data, 2019, 6(1): 1.

[16] SWAIN M C, COLE J M. ChemDataExtractor: a toolkit for automated extraction of chemical information from the scientific literature[J]. Journal of Chemical Information and Modeling, 2016, 56(10): 1894.

[17] BIRD S, KLEIN E, LOPER E. Natural language processing with Python[M]. Beijing: O'Reilly, 2009.

[18] HONNIBAL M, JOHNSON M. An improved non-monotonic transition system for dependency parsing[C]// Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA, USA: Association for Computational Linguistics, 2015: 1373.

[19] JESSOP D M, ADAMS S E, WILLIGHAGEN E L, et al. OSCAR4: a flexible architecture for chemical text-mining[J]. Journal of Cheminformatics, 2011, 3(1): 41.

[20] HAWIZY L, JESSOP D M, ADAMS N, et al. ChemicalTagger: a tool for semantic text-mining in chemistry[J]. Journal of Cheminformatics, 2011, 3(1): 17.

[21] LEAMAN R, WEI C H, LU Z Y. tmChem: a high performance approach for chemical named entity recognition and normalization[J]. Journal of Cheminformatics, 2015, 7(Suppl 1 Text mining for chemistry and the CHEMDNER track): S3.

[22] HARRIS Z S. Distributional structure[J]. WORD, 1954, 10(2/3): 146.

[23] PENNINGTON J, SOCHER R, MANNING C. Glove: global vectors for word representation[C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Stroudsburg: Association for Computational Linguistics, 2014: 1532.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[24] MIKOLOV T, SUTSKEVER I, CHEN K, et al. Distributed representations of words and phrases and their compositionality [EB/OL]. 2013: arXiv: 1310.4546. https://arxiv.org/abs/1310.4546

[25] BOJANOWSKI P, GRAVE E, JOULIN A, et al. Enriching word vectors with subword information[J]. Transactions of the Association for Computational Linguistics, 2017, 5: 135.

[26] HUANG L Y, LING C. Representing multiword chemical terms through phrase-level preprocessing and word embedding [J]. ACS Omega, 2019, 4(20): 18510.

[27] WESTON L, TSHITOYAN V, DAGDELEN J, et al. Named entity recognition and normalization applied to large-scale information extraction from the materials science literature[J]. Journal of Chemical Information and Modeling, 2019, 59(9): 3692.

[28] KIM E, JENSEN Z, VAN GROOTEL A, et al. Inorganic materials synthesis planning with literature-trained neural networks[J]. Journal of Chemical Information and Modeling, 2020, 60(3): 1194.

[29] LEAMAN R, GONZALEZ G. Banner: an executable survey of advances in biomedical named entity recognition[C]// Biocomputing 2008. Hawaii: WORLD SCIENTIFIC, 2007: 652.

[30] HE T J, SUN W H, HUO H Y, et al. Similarity of precursors in solid-state synthesis as text-mined from scientific literature[J]. Chemistry of Materials, 2020, 32(18): 7861.

[31] SHAH S, VORA D, GAUTHAM B P, et al. A relation aware search engine for materials science[J]. Integrating Materials and Manufacturing Innovation, 2018, 7(1): 1.

[32] TCHOUA R B, AJITH A, HONG Z, et al. Creating Training Data for Scientific Named Entity Recognition with Minimal Human Effort[C]//International Conference on Computational Science. Cham: Springer, 2019: 398.

[33] HISZPANSKI A M, GALLAGHER B, CHELLAPPAN K, et al. Nanomaterial synthesis insights from machine learning of scientific articles by extracting, structuring, and visualizing knowledge[J]. Journal of Chemical Information and Modeling, 2020, 60(6): 2876.

[34] VAUCHER A C, ZIPOLI F, GELUYKENS J, et al. Automated extraction of chemical synthesis actions from experimental procedures[J]. Nature Communications, 2020, 11(1): 3601.

[35] LOWE D M, SAYLE R A. LeadMine: a grammar and dictionary driven approach to entity recognition[J]. Journal of Cheminformatics, 2015, 7(1): S5.

[36] KIM E, HUANG K, TOMALA A, et al. Machine-learned and codified synthesis parameters of oxide materials[J]. Scientific Data, 2017, 4(1): 1.

[37] BAEVSKI A, EDUNOV S, LIU Y H, et al. Cloze-driven pretraining of self-attention networks[EB/OL]. 2019: arXiv: 1903.07785. https://arxiv.org/abs/1903.07785

[38] LI X Y, SUN X F, MENG Y X, et al. Dice loss for data-imbalanced NLP tasks[EB/OL]. 2019: arXiv: 1911.02855. https://arxiv.org/abs/1911.02855

[39] KONONOVA O, HE T J, HUO H Y, et al. Opportunities and challenges of text mining in aterials research[J]. iScience, 2021, 24(3): 102155.

[40] DIEB T M, YOSHIOKA M, HARA S, et al. Framework for automatic information extraction from research papers on nanocrystal devices[J]. Beilstein Journal of Nanotechnology, 2015, 6: 1872.

[41] FRIEDRICH A, ADEL H, TOMAZIC F, et al. The SOFC-exp corpus and neural approaches to information extraction in the materials science domain[C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA, USA: Association for Computational Linguistics, 2020: 03039.

[42] WANG Z R, CRUSE K, FEI Y X, et al. ULSA: unified language of synthesis actions for the representation of inorganic synthesis protocols[J]. Digital Discovery, 2022, 1(3): 313

[43] EL-BOUSIYDY H, TRONCOSO J F, JOHANSSON P, et al. LIBAC: an annotated corpus for automated "reading" of the lithium-ion battery research literature[J]. Chemistry of Materials, 2023, 35(5): 1849.

[44] ONISHI T, KADOHIRA T, WATANABE I. Relation extraction with weakly supervised learning based on process-structure-property-performance reciprocity[J]. Science and Technology of Advanced Materials, 2018, 19(1): 649.

[45] KUNIYOSHI F, MAKINO K, OZAWA J, et al. Annotating and extracting synthesis process of all-solid-state batteries from scientific literature[EB/OL]. 2020: arXiv: 2002.07339. https://arxiv.org/abs/2002.07339

[46] MYSORE S, JENSEN Z, KIM E, et al. The materials science procedural text corpus: annotating materials synthesis procedures with shallow semantic structures[C]// Proceedings of the 13th Linguistic Annotation Workshop. Stroudsburg: Association for Computational Linguistics, 2019: 56.

[47] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all You need[EB/OL]. 2017: arXiv: 1706.03762. https://arxiv.org/abs/1706.03762

[48] LEE J, YOON W, KIM S, et al. BioBERT: a pre-trained biomedical language representation model for biomedical text mining[J]. Bioinformatics, 2020, 36(4): 1234.

[49] BELTAGY I, LO K, COHAN A. SciBERT: a pretrained language model for scientific text[EB/OL]. 2019: arXiv: 1903.10676. https://arxiv.org/abs/1903.10676

[50] ALSENTZER E, MURPHY J R, BOAG W, et al. Publicly available clinical BERT embeddings[EB/OL]. 2019: arXiv: 1904.03323. https://arxiv.org/abs/1904.03323

[51] LIBOVICKY J, ROSA R, FRASER A. On the language neutrality of pre-trained multilingual representations[C]// Findings of the Association for Computational Linguistics: EMNLP 2020. Stroudsburg, PA, USA: Association for Computational Linguistics, 2020: 05160.

[52] LEE J S, HSIANG J. Patent classification by fine-tuning BERT language model[J]. World Patent Information, 2020, 61: 101965.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[53] ARACI D. FinBERT: financial sentiment analysis with pre-trained language models[EB/OL]. 2019: arXiv: 1908.10063. https://arxiv.org/abs/1908.10063

[54] GUPTA T, ZAKI M, ANOOP KRISHNAN N M, et al. MatSciBERT: a materials domain language model for text mining and information extraction[J]. Npj Computational Materials, 2022, 8(1): 1.

[55] ZHAO J Y, HUANG S, COLE J M. OpticalBERT and OpticalTable-SQA: text-and table-based language models for the optical-materials domain[J]. Journal of Chemical Information and Modeling, 2023, 63(7): 1961.

[56] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[EB/OL]. 2020: arXiv: 2005.14165. https://arxiv.org/abs/2005.14165

[57] OUYANG, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[EB/OL]. 2022: arXiv: 2203.02155. https://arxiv.org/abs/2203.02155

[58] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models[EB/OL]. 2020: arXiv: 2001.08361. https://arxiv.org/abs/2001.08361

[59] DECOST B L, LEI B, FRANCIS T, et al. High throughput quantitative metallography for complex microstructures using deep learning: a case study in ultrahigh carbon steel[J]. Microscopy and Microanalysis, 2019, 25(1): 21.

[60] AZIMI S M, BRITZ D, ENGSTLER M, et al. Advanced steel microstructural classification by deep learning methods[J]. Scientific Reports, 2018, 8(1): 2128.

[61] GOLA J, WEBEL J, BRITZ D, et al. Objective microstructure classification by support vector machine (SVM) using a combination of morphological parameters and textural features for low carbon steels[J]. Computational Materials Science, 2019, 160: 186.

[62] KIM H, HAN J, HAN T Y J. Machine vision-driven automatic recognition of particle size and morphology in SEM images[J]. Nanoscale, 2020, 12(37): 19461.

[63] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the inception architecture for computer vision[C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE Press, 2016: 2818.

[64] JUNG G, JUNG S G, COLE J M. Automatic materials characterization from infrared spectra using convolutional neural networks[J]. Chemical Science, 2023, 14(13): 3600.

[65] MUKADDEM K T, BEARD E J, YILDIRIM B, et al. ImageDataExtractor: a tool to extract and quantify data from microscopy images[J]. Journal of Chemical Information and Modeling, 2020, 60(5): 2492.

[66] PARK J, ROSANIA G R, SHEDDEN K A, et al. Automated extraction of chemical structure information from digital raster images[J]. Chemistry Central Journal, 2009, 3: 4.

[67] FILIPPOV I V, NICKLAUS M C. Optical structure recognition software to recover chemical information: OSRA, an open source solution[J]. Journal of Chemical Information and Modeling, 2009, 49(3): 740. s

[68] BEARD E J, COLE J M. ChemSchematicResolver: a toolkit to decode 2D chemical diagrams with labels and R-groups into annotated chemical named entities[J]. Journal of Chemical Information and Modeling, 2020, 60(4): 2059.

[69] MAVRAČIC J, COURT C J, ISAZAWA T, et al. ChemDataExtractor 2.0: autopopulated ontologies for materials science [J]. Journal of Chemical Information and Modeling, 2021, 61 (9): 4280.

[70] HERZIG J, NOWAK P K, MüLLER T, et al. TaPas: weakly supervised table parsing via pre-training[C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA, USA: Association for Computational Linguistics, 2020: 4320.

[71] CHEMMENGATH S A, KUMAR V, BHARADWAJ S, et al. Topic transferable table question answering [EB/OL]. 2021: arXiv: 2109.07377. https://arxiv.org/abs/2109.07377

[72] BLOKHIN E, VILLARS P. The PAULING FILE Project and Materials Platform for Data Science: From Big Data Toward Materials Genome[M]//ANDREONI W, YIP S. Handbook of Materials Modeling. Cham: Springer, 2018: 1.

[73] RACCUGLIA P, ELBERT K C, ADLER P D F, et al. Machine-learning-assisted materials discovery using failed experiments[J]. Nature, 2016, 533(7601): 73.

[74] COURT C J, COLE J M. Auto-generated materials database of Curie and Néel temperatures via semi-supervised relationship extraction[J]. Scientific Data, 2018, 5(1): 1.

[75] HUANG S, COLE J M. A database of battery materials auto-generated using ChemDataExtractor[J]. Scientific Data, 2020, 7(1): 1.

[76] GALLEGO S V, PEREZ-MATO J M, ELCORO L, et al. MAGNDATA: towards a database of magnetic structures. I. The commensurate case[J]. Journal of Applied Crystallography, 2016, 49(5): 1750.

[77] GHADBEIGI L, HARADA J K, LETTIERE B R, et al. Performance and resource considerations of Li-ion battery electrode materials[J]. Energy and Environmental Science, 2015, 8(6): 1640.

[78] WANG Z R, KONONOVA O, CRUSE K, et al. Dataset of solution-based inorganic materials synthesis procedures extracted from the scientific literature[J]. Scientific Data, 2022, 9 (1): 1.

[79] YOUNG S R, MAKSOV A, ZIATDINOV M, et al. Data mining for better material synthesis: the case of pulsed laser deposition of complex oxides[J]. Journal of Applied Physics, 2018, 123(11): 115303.

[80] DE CASTRO P B, TERASHIMA K, YAMAMOTO T D, et al. Machine-learning-guided discovery of the gigantic magnetocaloric effect in HoB2 near the hydrogen liquefaction temperature[J]. NPG Asia Materials, 2020, 12(1): 1.

[81] CRUSE K, TREWARTHA A, LEE S, et al. Text-mined dataset of gold nanoparticle synthesis procedures, morphologies, and size entities[J]. Scientific Data, 2022, 9(1): 1.

[82] COURT C J, COLE J M. Magnetic and superconducting phase

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

diagrams and transition temperatures predicted using text mining and machine learning[J]. Npj Computational Materials, 2020, 6: 18.

[83] ZHAO J Y, COLE J M. Reconstructing chromatic-dispersion relations and predicting refractive indices using text mining and machine learning[J]. Journal of Chemical Information and Modeling, 2022, 62(11): 2670.

[84] BEARD E J, SIVARAMAN G, VáZQUEZ-MAYAGOITIA á, et al. Comparative dataset of experimental and computational attributes of UV/vis absorption spectra[J]. Scientific Data, 2019, 6(1): 1.

[85] KIM E, HUANG K, SAUNDERS A, et al. Materials synthesis insights from scientific literature via text extraction and machine learning[J]. Chemistry of Materials, 2017, 29(21): 9436.

[86] TSHITOYAN V, DAGDELEN J, WESTON L, et al. Unsupervised word embeddings capture latent knowledge from materials science literature[J]. Nature, 2019, 571(7763): 95.

[87] KIM E, HUANG K, JEGELKA S, et al. Virtual screening of inorganic materials synthesis parameters with deep learning [J]. Npj Computational Materials, 2017, 3(1): 1.

[88] JENSEN Z, KWON S, SCHWALBE-KODA D, et al. Discovering relationships between OSDAs and zeolites through data mining and generative neural networks[J]. ACS Central Science, 2021, 7(5): 858.

[89] KARPOVICH C, PAN E, JENSEN Z, et al. Interpretable machine learning enabled inorganic reaction classification and synthesis condition prediction[J]. Chemistry of Materials, 2023, 35(3): 1062.

[90] 单斌, 蓝宇啸, 文艳伟, 等. 金属前驱体区域选择性原子层沉积机制[J]. 金属功能材料, 2021, 28(2): 1.

[91] 单斌, 陈荣昕, 杨家强, 等. Monolith 多尺度模型前沿进展: 从有限元方法到机器学习[J]. 金属功能材料, 2022, 29(3): 1.

[92] CAO K, CAI J M, CHEN R. Inherently selective atomic layer deposition and applications[J]. Chemistry of Materials, 2020, 32(6): 2195.

[93] CAI J M, LIU Z, CAO K, et al. Highly dispersed Pt studded on CoO_x nanoclusters for CO preferential oxidation in H_2[J]. Journal of Materials Chemistry A, 2020, 8(20): 10180.

[94] CAO K, SHI L, GONG M, et al. Nanofence stabilized platinum nanoparticles catalyst via facet-selective atomic layer deposition[J]. Small, 2017, 13(32): 1700648.

[95] CAO K, GONG M, YANG J F, et al. Nickel catalyst with atomically-thin meshed cobalt coating for improved durability in dry reforming of methane[J]. Journal of Catalysis, 2019, 373: 351.

[96] WEN Y W, CAI J M, ZHANG J, et al. Edge-selective growth of MCp_2 (M = Fe, Co, and Ni) precursors on Pt nanoparticles in atomic layer deposition: a combined theoretical and experimental study[J]. Chemistry of Materials, 2019, 31(1): 101.

[97] YANG J Q, CAO K, HU Q, et al. Unravelling the selective growth mechanism of AlO_x with dimethylaluminum isopropoxide as a precursor in atomic layer deposition: a combined theoretical and experimental study[J]. Journal of Materials Chemistry A, 2020, 8(8): 4308.

[98] LAN Y X, WEN Y W, LI Y C, et al. Selectivity dependence of atomic layer deposited Manganese oxide on the precursor ligands on platinum facets[J]. Journal of Vacuum Science & Technology A, 2023, 41(1): 012402.

[99] WALKER N, TREWARTHA A, HUO H Y, et al. The impact of domain-specific pre-training on named entity recognition tasks in materials science[J]. SSRN Electronic Journal, 2021: 3950755.

[100] VALDESUEIRO D, GARCIA-TRI? ANES P, MEESTERS G M H, et al. Enhancing the activation of silicon carbide tracer particles for PEPT applications using gas-phase deposition of alumina at room temperature and atmospheric pressure[J]. Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment, 2016, 807: 108.

[101] WANG Y Y, YU Z M, YANG Y, et al. Bright red electroluminescence from Al_2O_3/Eu_2O_3 nanolaminate films fabricated by atomic layer deposition on silicon[J]. Scripta Materialia, 2021, 196: 113750.

陈蓉(Rong CHEN),华中科技大学机械科学与工程学院教授、博士生导师、华中科技大学柔性电子研究中心副主任。国家级创新领军人才(2015),海外高层次青年人才(2011),2021 年"科学探索奖"获得者。承担国基金重点项目、973 青年项目等多项微电子与新能源相关项目,在 Nat. Comm., Adv Mater, Angew. Chem. Int. Ed, Small, Sci. Bullet., IJEM, OEA 等国内外期刊上发表 SCI 论文 140 余篇,主编撰写中英文出版物 3 部,获授权专利 80 余项、含 10 余项国际专利。以排名第一荣获湖北省技术发明一等奖、湖北省专利奖、全国颠覆性技术创新大赛优胜奖、入选 2020"科创中国-先导技术榜单"等。在国际上,获得 IEEE SMC 杰出学术贡献奖、日内瓦发明展特别金奖等。主要研究方向:原子层沉积方法、工艺与装备的研究。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net