文章编号:1674-9146(2025)03-084-06

跨境电商用户评论文本挖掘*

周 宓

(泉州师范学院数学与计算机科学学院，福建 泉州 362000)

摘 要:介绍了电商用户评论文本挖掘及其作用，阐述了文本挖掘的相关理论，详细介绍了文本挖掘的过程，包括数据预处理、数据清洗、数据分析及基于自然语言处理（NLP）的非结构化文本分析过程。结果表明，用户评论可以帮助企业更好地理解用户需求、改进产品和服务，提高客户满意度。

关键词:跨境电商;用户评论;文本挖掘;NLP;非结构化文本

中图分类号:F713.36;TP18;TP274 **文献标识码**:A DOI:10.3969/j.issn.1674-9146.2025.03.084

1 研究背景

跨境电商是指通过互联网平台进行国际贸易的电子商务活动。它允许消费者在不同国家或地区之间进行在线购物和交易，打破了传统贸易的边界限制。消费者可以轻松地从其他国家或地区购买产品，跨境电商平台也能够为商家提供更广阔的市场机会。亚马逊是一家跨领域的电子商务巨头，通过不断创新和扩展业务，为全球消费者带来了便利和多样化的购物选择。

在电商企业日常的产品和运营工作中，经常接触的数据分析方法，形式绝大部分基于对数字（值）的描述性分析。这些数据被称为结构化数据。除此之外，图片、文字、视频统称为非结构化数据。非结构化数据蕴含信息量大，特别是文本信息（用户评论），是用户对产品、服务是否满意的重要了解手段。对于非自营电商类业务，文本数据显得异常重要。这是因为作为第三方卖家触达用户手段有限，只能通过平台暴露出的数据接口。而能够通过平台获得的非结构化数据主要是指用户评论数据。

跨境电商用户的反馈和意见至关重要。用户评论是了解消费者对产品质量、包装、交付时间、售后服务等方面的评价的重要途径。通过分析用户评论，企业可以了解用户对产品和服务的满意度，找到存在的问题并及时改进。用户评论中蕴含着消费者的需求和偏好信息。通过分析用户评论中的关键词、主题和情感，企业可以洞察用户对产品功能、设计、价格等方面的看法，为产品策划和定位提供参考。积极的用户评论可以增强品牌形象和口碑，而消极的用户评论则可能对品牌声誉造成负面影响。通过挖掘用户评论，企业可以及时回应和处理用户关切，维护良好的品牌形象。

用户评论不仅涵盖了自家产品的反馈，还包括对竞争对手产品的评价。通过分析竞争对手的用户评论，企业可以掌握市场上其他品牌或产品的优势和不足，为自身产品的差异化竞争提供依据。

2 文本挖掘基本理论

2.1 网络爬虫

网络爬虫是一种自动化程序[1],用于从互联网上收集数据。它可以浏览网页，提取信息，并将其存储在数据库或其他形式的存储器中。

网络爬虫工作的基本原理是通过发送 HTTP 请求到目标网站，然后解析返回的 HTML 页面，提取所需的信息。网络爬虫可以根据预定义的规则自动跟踪和访问链接，以获取更多的数据。其原理主要可以分为以下 6 个步骤。

1) 定义起始 URL：网络爬虫需要指定一个或多个起始 URL 作为开始点。这些 URL 通常是用户提供的初始页面或搜索引擎的搜索结果页面。

2) 发送 HTTP 请求：网络爬虫会使用 HTTP 协议向目标 URL 发送请求，并等待服务器的响应。请求可以是 GET、POST 或其他 HTTP 方法。

3) 解析 HTML 响应：当服务器返回响应后，网络爬虫会解析 HTML 代码，提取出其中的链接、文本和其他所需的数据。这通常通过使用解析库（如 BeautifulSoup）来实现。

[基金项目] 福建省中青年教师教育科研项目(科技类)(JAT210312;JAT220828)

收稿日期:2024-04-04;修回日期:2024-04-29

作者简介:周 宓(1981—),女,福建泉州人,硕士,讲师,主要从事计算机技术及教学研究,E-mail:43851707@qq.com。

中国知网 https://www.cnki.net

4）提取数据：在解析 HTML 响应的过程中，网络爬虫会根据预定义的规则从 HTML 代码中提取所需的数据。这可以是链接、文本、图像、视频等。

5）存储数据：提取到的数据可以存储到本地文件或数据库中，供后续处理和分析使用。

6）遍历链接：网络爬虫会将从 HTML 代码中提取到的链接添加到待访问的 URL 列表中，并继续重复以上步骤，直到达到设定的停止条件（如达到最大爬取深度或已访问所有目标页面）。

网络爬虫可以用于各种用途，例如搜索引擎索引网页内容、价格比较、数据挖掘、舆情监测等。但需要注意的是，在使用网络爬虫时，必须遵守网站的使用政策和法律法规，尊重隐私权和知识产权。

为了避免对目标网站造成过大的负担或滥用，开发者通常会设置网络爬虫的爬取速度、频率和深度限制。此外，还应该注意合理使用代理服务器、遵守 robots.txt 协议等规范，以确保网络爬虫的合法性和道德性。

2.2　NLP

自然语言处理（Natural Language Processing，NLP）是指计算机科学与人工智能领域中研究人类语言和计算机之间的交互的技术和方法[2]。它涉及了对自然语言进行理解、分析、生成和处理的各种任务。NLP 可以用于多种应用，包括机器翻译、情感分析、文本分类、命名实体识别、问答系统、文本摘要、语音识别、对话系统等。

机器不懂人类的自然语言，要将自然语言转换为机器易于理解的“语言”。在 NLP 中，常用的技术包括词法分析、句法分析、语义分析、机器学习和深度学习等。NLP 里，最细粒度的是词语，词语组成句子，句子再组成段落、篇章、文档[2]。

因此，处理 NLP 的问题，首先要处理词语。分词阶段将一句话拆分成一个一个单词，英文直接通过空格就可以分词，而中文分词可以借助 jieba 这样的第三方库。

接着，需要将有屈折变化的单词还原成未变化的单词，即词干提取（stemming）。词干提取是去除单词的前后缀得到词根的过程。大家常见的前后词缀有名词的复数、进行时、过去分词等。

然后，进行词形还原（lemmatization）。词形还原是基于词典，将单词的复杂形态转变成最基础的形态[3]。词形还原不是简单地将前后缀去掉，而是会根据词典将单词进行转换。比如“drove”会转换为“drive”。获取原始单词之后还需要去掉停用词和一些助词、虚词、连词。停用词（stop word）可以手动指定，这些单词经过处理之后不会保留在分词结果中。一般人们只关心名词、动词和形容词。上述过程都有第三方库帮助人们实现。

NLP 的发展受益于大数据和强大的计算能力，以及不断进步的算法和模型。随着技术的不断进步，NLP 在日常生活和商业领域中的应用越来越广泛，为人们提供了更智能、便捷的交互方式。

2.3　用户评论分析

用户评论分析通常包括以下 6 个步骤。

1）数据收集：通过网络爬虫或应用编程接口（Application Programming Interface，API）等方式，收集用户在不同平台上发布的评论数据，如社交媒体、电子商务网站、论坛等。

2）数据清洗：对收集到的评论数据进行预处理，去除噪声数据、非法信息以及重复评论等。

3）情感分析：使用自然语言处理技术，对每条评论进行情感分类，判断其是积极、消极还是中性的。常用的方法包括基于规则的方法和机器学习方法。

4）主题提取：通过文本挖掘技术，从评论中识别出涉及的主题或话题。这可以帮助企业了解用户对不同方面的关注点和兴趣。

5）关键词提取：提取评论中的关键词，以便更好地理解用户的关注点和需求。

6）反馈总结：根据对评论的分析结果，对用户的反馈和意见进行总结和归纳，提炼出有价值的见解和改进建议。

3　数据预处理

3.1　数据来源与数据描述

数据来源为从 Kaggle 官网上下载亚马逊电商平台上手机商品的用户评论数据。商品评论由用户 ID、评分星级、评论时间、评论文本等内容组成。商品评论示意图见图 1。

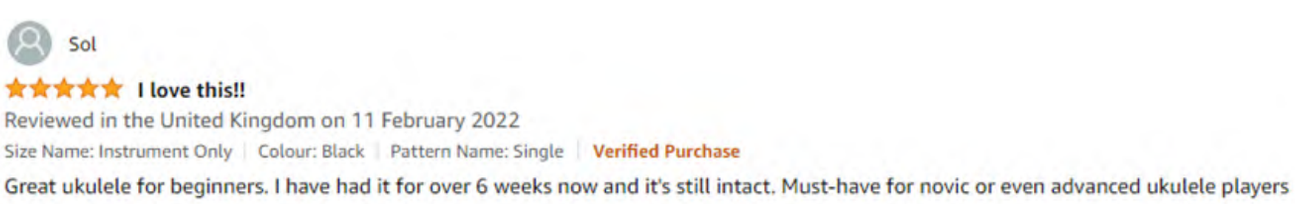

图 1　商品评论示意图

中国知网　https://www.cnki.net

3.2　数据清洗

3.2.1　缺失值处理

缺失值处理是在数据分析和建模过程中常见的任务，它涉及到处理数据集中存在的缺失或空值情况。缺失值可能是由于数据采集过程中的错误、设备故障、用户不完整的响应等原因导致的。抓取到的数据信息见图 2。

其中，asin 列为亚马逊商品标准识别码，在亚马逊平台上具有唯一性；name 列为发表评论的用户名；rating 列为评分星级；date 列为评论时间；verified 列为购买确定，即评论用户是否购买了此商品；title 列为简短评价；body 列为用户评论具体描述；helpVotes 列为多少人认为有用。

asin	name	rating	date	verified	title	body	helpfulVotes
B002UHS0	Victor	5	12-Mar-18	TRUE	Five Stars	Lovely mer	1
B002UHS0	ing.jsantos	1	7-Jul-19	TRUE	the battery	the cell phone is broken	
B002UHS0	Kasie B	1	3-Jun-16	TRUE	Got it in th	Got it in th	1
B002UHS0	Sandra Jor	5	26-Jan-19	TRUE	:/	Nice phone, suck company.	
B002UHS0	Fred Farrol	1	9-Mar-13	TRUE	Dead on A	This phone	10
B002UHS0	T DOSS	1	5-Jan-17	TRUE	One Star	Bad batter	2

图 2　数据信息

使用 info（）查看数据分布情况，结果见图 3。

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 67986 entries, 0 to 67985
Data columns (total 8 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   asin          67986 non-null  object
 1   name          67983 non-null  object
 2   rating        67986 non-null  int64
 3   date          67986 non-null  object
 4   verified      67986 non-null  bool
 5   title         67957 non-null  object
 6   body          67960 non-null  object
 7   helpfulVotes  27215 non-null  float64
dtypes: bool(1), float64(1), int64(1), object(5)
memory usage: 3.7+ MB
```

图 3　数据分布情况

从图 3 可以看出，body 数据有缺失，但是只有 26 条，由于要对文本评论内容进行分析，故直接删除缺失数据。name 的缺失对数据分析结果没有影响，可不作处理。最终处理后的数据有 67 960 条。

3.2.2　标记评价类型

根据星级数量 rating 判断用户评论的等级，将其转化成好评、中评和差评。其中星级小于等于 2 的评论，定为差评；星级等于 3 的评论，定为中评；星级大于 3 的评论，定为好评。同时添加一个字段 review_cate，用来记录该评价类型，并统计各评论类型数量，结果见图 4。

```
review_cate
好评    46558
差评    16650
中评     4752
Name: count, dtype: int64
```

图 4　各评论类型数量

3.2.3　获取评论中 date 的年月日

评论中的 date 的形式为“June 24, 2020”，用“,”拆分得到日月和年，再用空格拆分出月和日，最后将分离出的年、月、日拼接在一起，得到完整的年月日时间，增加一列 date_d 用以保存。

3.3　数据分析

接下来将竞品销售情况细化。通过对竞品评论中分型号的历史评论数量，反推竞品的主要售卖产品的情况，分析竞品高分和低分的评论内容，高分 4~5 分的用户评论主要说哪些，低分 1~2 分用户评论主要说什么，人们比较关注的方面又说了什么。

3.3.1　统计各商品评论数量

根据商品的唯一标识 asin 统计产品的评论数量，并显示评论数量前 10 的商品评论数，结果见图 5。

```
B00F2SKPIM    981
B00836Y6B2    925
B07FZH9BGV    791
B01D1J9BGU    774
B07WSJYDXX    773
B018OMP8ES    772
B013XAPUW6    772
B00HPP3QD6    771
B076XLLCQC    766
B06Y16RL4W    745
Name: asin, dtype: int64
```

图 5　评论数量前 10 的商品

3.3.2　统计每种商品不同类型评论数量

使用 seaborn 提供的 FacetGrid（）构建结构化多绘图网格，不同子集上绘制同一图的多个实例。不同商品的不同类型评论数量结果见图 6。

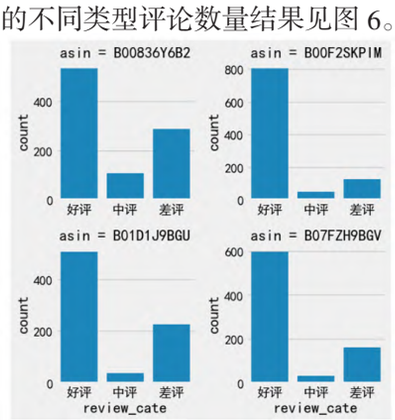

图 6　不同商品的不同类型评论数量

中国知网　https://www.cnki.net

3.3.3　按时间顺序统计发文数量

按时间顺序统计发文数量，分析评论发表是否有周期性规律，结果见图 7。从图 7 可以看出，每年的一月、二月、七月是评价发布的高峰期。评论数量的时间分布反映出商品的销售情况是有周期性的，即年中和年底是销售的高峰期。

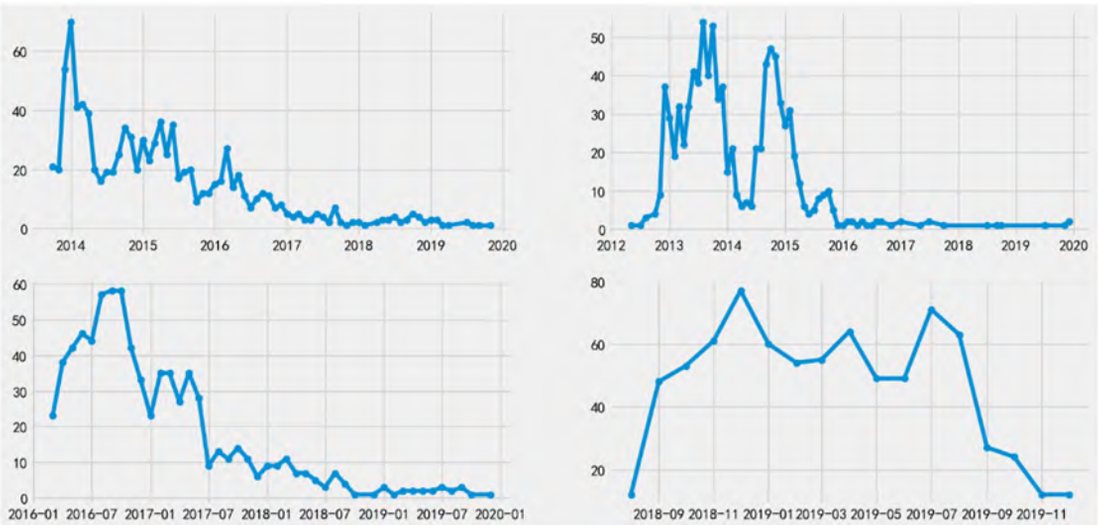

图 7　按时间顺序统计发文数量

3.3.4　好中差评随时间分布

选取评论中数量最多的 4 种商品，按时间顺序统计分别统计好中差评发文数量随时间分布，寻找其规律，结果见图 8。

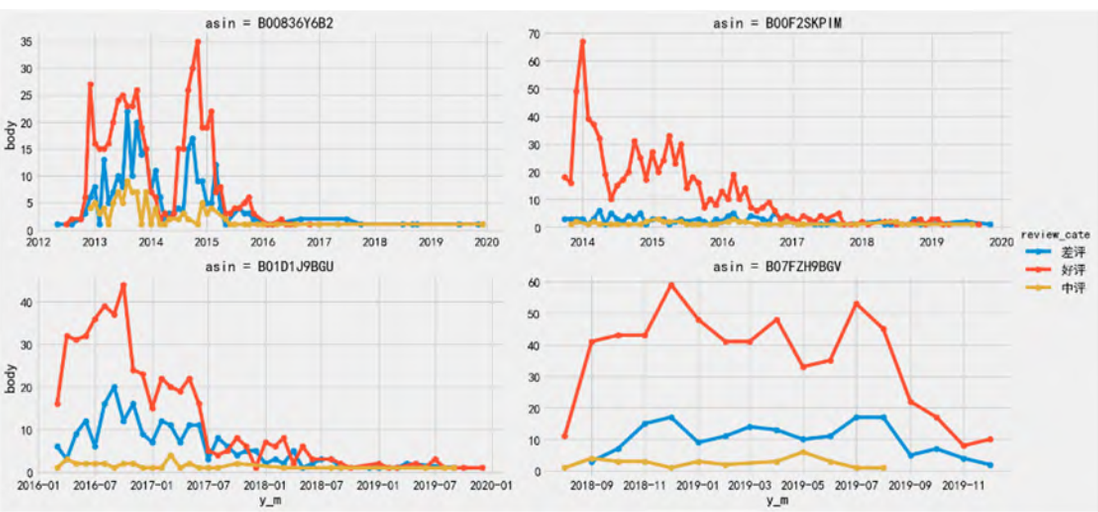

图 8　按时间顺序分别统计好中差评发文数量

4　非结构化数据文本的分析

在上述结构化分析的基础上，使用自然语言处理的第三方库 nltk 对评论文本进行非结构化分析。

4.1　文本去重

文本去重是指在一个文本集合中，识别和删除重复的文本数据。这在文本分析、信息检索和数据清洗等任务中是常见的预处理步骤，以减少冗余数据并提高后续分析的效率和准确性。

当顾客长时间没有及时评论，平台默认好评或者人为复制粘贴其他人的评论内容时，会重复出现大量无价值无意义的评论，分析这部分数据对于挖掘文本数据潜在信息没有好处，同时会影响评论结果的准确性，所以要对这部分数据进行文本去重处理。使用 drop_duplicates 对评论信息进行去重[4]。

4.2　分词、词形还原 (lemmatization)

词形还原（lemmatization）是一种文本预处理技术，它是将单词还原为其原始形式（称为词元或词根），以减少词汇的变体形式对文本分析的影响。词形还原有助于将具有相同语义的不同词形视为同一个词，并提高文本分析任务（如信息检索、情感分析等）的准确性。基于词典的词形还原是使用词典或词形还原表来查找和匹配词形变化。词典中包含了单词的不同变体和它们的原始形式。例如，将“mice”还原为“mouse”，将“better”还原为“good”等。这种方法可以处理更广泛的词汇变体，但需要维护和更新大型的词典。使用 nltk 包中的

中国知网　https://www.cnki.net

morphy 方法来做词形还原。

4.3　去停用词

从分词结果来看，文本中会有一些出现频率很高但并无明确意义的词语，比如语气助词、介词、副词之类的词语[4]。这些不想保留的单词就是停用词（stop word）。如果过多使用这些词语，可能无法得到精确结果，影响后续分析。因此，通过构建停用词库，对这些词语进行过滤[4]。

nltk 提供了一个基础的停用词库，在 nltk_data\corpora\stopwords\english。如果想添加新的停用词，可以直接修改这个文件，用记事本打开，每个词一行，在最后一行追加就可以了。过滤用户评论文本中在停用词表里的词，去停用词后的部分分词表见表 1。

表 1　去停用词后的部分分词表

序号	分词结果
1	'really', 'love', 'Galaxy', 'Note', '3', 'absolutely', 'problem', 'It', 'doe', 'everything', 'sorry', 'new', 'version', '7', 'ha', 'disaster', 'think', 'must', 'flaw', 'seal', 'waterproof', 'design', 'glad', 'settle', 'older', 'version', 'try', 'true', 'le', 'money', 'virtually', 'side', 'Galaxy', 'Note', '3', 'phone', 'awesome', 'phone', 'feel', 'badly', 'company', 'time', 'Also', 'company', 'sent', 'quickly', 'Arrived', 'earlier', 'expect'
2	'Amazingly', 'works', 'Tracfone', 'Before', 'use', 'iPhone', '4', 'Verizon', 'buy', 'Amazon', 'transfer', 'Tracfone', 'BYOP', 'successfully', 'everything', 'still', 'works'
3	'This', 'phone', 'fabulous', 'iPhone', '4', 'really', 'need', 'anything', 'fancy', 'better', 'get', 'tire', 'update', '4', 'old', 'many', 'new', 'things', 'want', 'something', 'could', 'read', 'book', 'large', 'enough', 'like'
4	'Worked', 'like', 'straight', 'box', 'It', 'great', 'able', 'charge', 'original', 'Note', '3', 'rust', 'corrode', 'around', 'port', 'It', 'little', 'tricky', 'figure'
5	'phone', 'little', 'month', 'extremely', 'happy', 'love', 'everything', 'EXCEPT', 'Visual', 'Voicemail', 'Update'
6	'This', 'phone', 'would', 'perfect', '10+', 'without', 'software/bloat'
7	'Great', 'phone', 'although', 'miss', 'integrate', 'feature', 'iPhone', 'provide', 'Excellent', 'battery'
8	'lock', 'screen', 'voice', 'command', 'universal', 'easily', 'accessible', 'like', 'Siri'

4.4　统计词频

评论信息中往往会出现些频率较高的词，称之为高频词汇，其中既有好评词语，又有差评词语。通过这些高频词汇能在一定程度上看出顾客对产品各项特征的关注情况，对于找出影响消费者满意度影响因素、了解消费者需求具有一定参考意义[5]。表 2、表 3 均展示了语料库中排名靠前的高频词汇及其频数。

4.5　绘制词云图

词云图是一种可视化工具，用于展示文本数据中出现频率较高的词汇。它通过将词语按照出现频率的大小进行排列，并根据词语的重要性和频率来调整词语的字体大小，从而形成一个视觉上富有吸引力的图像。

表 2　好评词语及其频数

好评词语	频数	好评词语	频数	好评词语	频数
phone	347	come	179	fast	129
love	310	samsung	170	well	123
great	261	buy	155	Buy	116
better	231	Quality	154	Easy	113
screen	213	Learn	154	also	108
Good	199	app	149	video	103
get	187	device	147	everything	101
use	185	fearure	145	really	100
Instrument	184	Like	137	need	97

表 3　差评词语及其频数

差评词语	频数	差评词语	频数	差评词语	频数
phone	184	Return	36	Cheap	26
work	76	money	35	Back	26
buy	68	buy	35	Money	26
use	60	Hold	35	Make	24
unlock	52	Better	34	fast	23
one	51	not	33	need	22
Instrument	45	picture	33	video	20
even	42	camera	28	Time	19
battery	37	Good	28	disappoint	18

词云图可以帮助人们更直观地了解文本数据中的关键词和主题。通过观察词语在词云图中的相对大小和位置，可以快速获取文本的主要内容和关注点。

使用 Pyecharts 的 WordCloud（）这个 API 绘制词云图，结果分别见图 9、图 10。

图 9　好评词云图

图 10　差评词云图

中国知网　https://www.cnki.net

5　结论

通过深入分析用户评论，企业可以更好地理解用户需求、改进产品和服务，提高客户满意度。用户评论中包含丰富的情感信息，通过情感分析技术可以识别用户评论中的情感倾向，如积极、消极或中性。这对于企业了解用户情感态度、品牌声誉的评估以及危机处理都非常有帮助，并在竞争激烈的跨境电商市场中取得竞争优势。

参考文献：

[1]　王纪才,徐启南,袁霄翔.基于 Python 爬虫的电影数据可视化分析[J].周口师范学院学报,2023,40(5):60-65.

[2]　蔡鑫,娄京生.基于 LSTM 深度学习模型的中国电信官方微博用户情绪分析[J].电信科学,2017,33(12):136-141.

[3]　郭博露,熊旭辉.基于深度学习的冒犯性语言检测方法综述[J].现代信息科技,2022,6(5):5-10.

[4]　汪静怡.基于在线评论的生鲜电商顾客满意度研究[D].济南:山东大学,2021.

[5]　胡迪.基于文本挖掘和情感分析的物流客户满意度测评研究[D].重庆:重庆邮电大学,2022.

（责任编辑　**邸开宇**）

Cross Border E-Commerce User Review Text Mining

ZHOU Mi

(School of Mathematics and Computer Science, Quanzhou Normal University, Quanzhou 362000, China)

Abstract: This paper introduces the text mining of e-commerce user reviews and its functions, expounds the relevant theories of text mining, and introduces the process of text mining in detail, including data preprocessing, data cleaning, data analysis and unstructured text analysis based on Natural Language Processing (NLP). The results show that user reviews can help enterprises better understand user needs, improve products and services, and improve customer satisfaction.

Key words: cross border e-commerce; user review; text mining; NLP; unstructured text

（上接第 83 页）

[3]　廖浚伶,吴凯,彭纪超,等.贵州兴义喀斯特地貌的同时态演化:纳灰峰林子系统和西侧峰丛子系统[J].贵州科学,2022,40(6):83-86.

[4]　冯关芳,钟智.荔波樟江风景名胜区喀斯特森林生态特点浅析[J].魅力中国,2009(16):147-148.

[5]　刘军会,邹长新,高吉喜,等.中国生态环境脆弱区范围界定[J].生物多样性,2015,23(6):725-732.

[6]　蔡淑芳,刘现,王涛,等.鱼菜共生系统经济可行性研究进展[J].江苏农业科学,2019,47(5):5-8.

[7]　杨思宇,朱浩辰,刘友晴,等.鱼菜共生发展与经济效益分析[J].养殖与饲料,2021,20(10):64-66.

[8]　徐琰斐,张宇雷,顾川川,等.鱼菜共生发展历史、典型模式与发展趋势[J].渔业现代化,2020,47(5):1-7.

[9]　陈国军,胡君易,林晓霞,等.EM 菌在鱼菜共生循环农业生产中的应用[J].现代农业研究,2022,28(6):111-113.

[10]　邓壮河."鱼菜共生"山区帆布池绿色低碳养鱼技术[J].当代水产,2022,47(8):80-81.

[11]　邓顺华,高立洪,郑吉澍,等.鱼菜共生耦合智能控制系统设计与试验[J].农业工程,2020,10(4):41-45.

[12]　张和顺,田利华,劳栋添,等.鱼菜共生立体栽培、气雾栽培生态循环种植技术应用现状及发展前景[J].安徽农学通报,2022,28(5):75-77.

[13]　刘慧,汪小旵,施印炎,等.鱼—菜共生种养技术模式研究现状[J].中国农机化学报,2022,43(12):75-82.

[14]　王长东.喀斯特地貌景区观景休憩点设计研究[D].西安:西安建筑科技大学,2010.

[15]　刘爽,安诗琦,严子微,等.现代鱼菜共生技术研究进展与展望[J].中国农业科技导报,2020,22(3):160-166.

[16]　李辉.鱼菜共生蔬菜栽培技术[J].农村新技术,2014(8):21-22.

[17]　刘海鹏.鱼菜共生系统的作用机理及其对现代农业发展的意义[J].中国食品,2021(19):142-143.

（责任编辑　**张志勇**）

Study on Technical Model of Aquaponics in Karst Eco-fragile Areas

CHEN Yongli, DENG Hansong, SHI Bing, ZHOU Dan, LIAO Mingxia

(Minzu Normal University of Xingyi, Xingyi 562400, China)

Abstract: Aquaponics system based on the concept of natural ecological circulation is a composite production system combining aquaculture and soilless cultivation. In order to solve the current situation of less available land area and difficult access to groundwater in karst areas, aquaponics technology is taken as the main line to study the current situation of aquaponics. Using a series of characteristics of the production system, such as small area, less water consumption, less environmental pollution, high economic benefit, low demand for land resources, good ecological benefit and high ornamental value, the "aquaponics" planting and breeding mode is developed in the karst eco-fragile areas, and reasonable planting and breeding technical suggestions are put forward.

Key words: eco-fragile area; aquaponics (fish and vegetable symbiosis); planting and breeding; karst

中国知网　https://www.cnki.net