毕业设计（论文）

文 献 综 述

网络文学 IP 价值评估及流行趋势分析平台研究综述

1 选题的背景、目的和意义

大数据挖掘与自然语言处理技术的迅猛发展为网络文学 IP 价值评估这一数字文化产业的关键分支注入了强大动力，使其进入了智能化决策的新阶段。与传统的“资深编辑人工审读+主观经验打分”模式相比，基于数据驱动的 IP 价值评估技术无需依赖昂贵且低效的人力资源，显著降低了评估成本，具备更高的客观性、实时性和全网覆盖能力，在影视改编投资[7-8]、数字娱乐、微短剧制作决策[2]等众多现实应用领域展现出巨大的应用潜力，并得到了广泛应用。机器学习与情感计算方法在海量非结构化文本处理上不断刷新认知，充分彰显了其在文学价值量化中的潜力和优势。这些方法能够自动从作品的点击数据、读者评论及互动行为中提取深层特征，不仅极大地提高了 IP 价值评估任务中对“爆款”预测的准确性，还显著增强了模型对新书“冷启动”阶段及复杂舆情变化的适应能力。展望未来，提升算法在跨平台数据孤岛下的融合性能以及探索如何更有效地利用时间序列中的增长趋势信息，以进一步提高 IP 潜力挖掘的效率和准确性，将成为研究的重点方向。可以预见，基于数据驱动的网络文学 IP 价值评估技术的研究和应用前景十分广阔，必将持续推动数字文创领域的技术创新与进步[6]。

本综述聚焦于基于多维数据挖掘的网络文学 IP 价值评估技术，旨在全面深入地分析和探讨其最新的研究进展。随着爬虫技术与深度学习算法的不断演进，该技术系统已具备强大的能力，能够从起点、纵横这两个异构平台中精准地分析并提取作品的多维价值特征，并且拥有处理大规模并发数据的卓越能力，从而实现对处于不同生命周期（成熟期与孵化期）作品的精确估计。这一技术在版权交易定价、投资风险风控、平台流量分发等多个关键应用领域都有着至关重要的实际应用价值。本综述特别着重于对“双引擎”模型优化工作的研究，致力于确保系统在维持高准确率的同时，能够迅速做出响应，以满足市场热点快速迁移的严格要求。最终，该系统将通过一个设计精良、用户友好的 Web 可视化界面，将价值雷达图与流行趋势画像直观地展示给用户，从而显著提升决策效率，为相关领域的商业投资和运营策略提供坚实而强有力的技术支撑[10]。

2 国内外研究现状及发展趋势

网络文学 IP 价值评估是数字内容资产管理领域中的一个重要研究方向，旨在从海量、异构的网络文学数据中精准量化并识别作品的商业价值、文学价值以及潜在的改编潜力[4]。随着大数据挖掘与自然语言处理（NLP）技术的快速发展，该领域已经从传统的“定性分析”过渡到了以“数据智能”为主导的新时代[5]。自各类统计模型首次被应用于 IP 评估以来，研究者们不断探索新的指标体系和算法模型，推动了价值评估技术的进步。国内外研究现状表明，尽管在指标构建和局部算法上已经取得了显著的成果，但仍存在许多挑战和优化空间，特别是在跨平台数据采集的鲁棒性（反爬攻防）[14,19]、“冷启动”阶段的预测精度[16]以及非结构化文本的情感语义理解等方面[15]。

2.1 国外研究现状

国外在 Web 数据挖掘与数字内容推荐领域的研究起步较早，已经形成了一套相对成熟的技术体系。国外研究者在 Web Scraping（网页爬虫）、情感计算以及推荐算法的设计和优化上具有深厚的理论基础和实践经验，特别是在非结构化数据处理、用户行为分析和产品生命周期管理等方面取得了一系列突破性成果。

例如，Khder[19]在 Web Scraping 领域的综述研究以及 Eslami 等人[16,18]提出的基于产品生命周期（PLC）的用户参与度模型均为国外研究者所提出，它们在数据获取的完整性和价值评估的动态性上都达到了国际领先水平。这些方法通过引入动态渲染解析技术和分阶段评估机制，显著提升了数据挖掘的性能，尤其是在处理高动态网页和分析不同生命周期产品价值驱动力方面的表现。

此外，国外研究者还在积极探索如何将情感分析技术与其他机器学习算法相结合，以实现更为复杂和高级的推荐任务，如销量预测、用户偏好洞察等。例如，Pavitha 等人[20]提出的结合余弦相似度与朴素贝叶斯的情感推荐系统，以及 Dhar 与 Bose[17]关于评论情感强度（Sentiment Intensity）的研究，标志着底层文本特征与高层用户心理信息的有效结合，为网络文学作品的“共情力”量化提供了强有力的支持。

与此同时，国外研究者也在关注数据挖掘技术在数据伦理和隐私保护方面的问题。随着《通用数据保护条例》（GDPR）等法规的出台，如何在合规采集数据的前提下，利用公开数据提升商业智能决策，成为了一个重要的研究方向。

2.2 国内研究现状

在国内，网络文学 IP 价值评估的研究同样呈现出蓬勃的发展态势。国内研究者紧跟国际技术步伐，不断探索和优化适应中文语境的评估模型[3]，以适应泛娱乐产业爆发式增长的实际应用场景。近年来，随着数字经济战略的推进，国内高校和研究机构纷纷投入到网络文学数据资产化的研究中[11]，形成了计算机科学、传播学与经济学多学科交叉的研究团队[12]，推动了技术的快速发展。

国内的研究重点在于如何结合中国特有的网络文学平台生态（如起点中文网、纵横中文网）和 IP 全产业链开发需求，开发出更加精准和高效的价值评估系统。例如，蔡新宇[11]创新性地引入了层次分析法（AHP）和模糊综合评价法（FCEM），解决了无形资产评估的量化难题；姜豪[8]则在处理粉丝粘性、付费意愿以及核心粉丝率等关键指标上取得了一定的进展，提出了一些创新性的方法来提升模型对头部 IP 的识别能力。此外，国内研究者也在积极探索 IP 评估技术在影视改编、微短剧制作、动漫游戏开发等领域的应用[2,9]，推动相关技术的产业化进程。研究团队利用深度学习模型对海量评论进行情感分析，帮助投资方更好地评估作品的市场口碑和改编风险[13]。在微短剧出海领域，基于趋势分析的题材挖掘系统被广泛应用于内容创作指导和流量分发等场景，提升了内容生产的智能化水平。这些应用不仅推动了技术的进步，也为文化产业的繁荣和数字资产的安全交易提供了保障[1]。

2.3 发展趋势

未来，网络文学 IP 价值评估技术将朝着更动态、精准、可解释的方向发展。

一方面，评估模型架构将不断优化，以更好地处理“冷启动”阶段的数据稀疏问题和非结构化文本的语义理解问题，提高价值评估的准确性。例如，研究人员可能会探索更复杂的深度学习架构，如引入 Transformer、BERT 等预训练语言模型以及无监督聚类技术（Unsupervised Clustering）与多维相似度分析算法，以增强模型对作品深层情感逻辑的关注和潜在价值的挖掘能力。

另一方面，随着平台更新数据的海量涌现，如何更有效地利用时间序列中的动态信息将成为研究热点，以实现更实时、连续的全生命周期价值监控。通过引入“更新熵”等动态风控指标，实时监测作者的履约稳定性，防止评估结果的滞后。

同时，跨领域应用将不断拓展，与更多学科进行深度融合，如与时空经济学结合，利用 ip_region 数据实现更精准的粉丝购买力画像与区域变现潜力分析；与社会心理学结合，用于研究读者情感共鸣机制与流行题材的演变模式等。

此外，在版权保护和算法可解释性（XAI）方面的研究也将不断加强，以确保技术在辅助商业决策时的透明度与合规性，推动行业建立统一的价值量纲与评估标准。

3 存在的问题与挑战

尽管国内外在相关领域已取得了丰硕成果，但针对网络文学这一特定场景的 IP 价值评估，仍存在以下主要技术瓶颈与现实挑战：

3.1 “冷启动”阶段的预测失效

现有的大多数模型（如 XGBoost 回归、随机森林）高度依赖作品的历史累计数据（如总点击、总字数）。然而，对于处于连载初期（孵化期）的新书，这些数据极其稀疏。传统模型往往会因为数据量小而给予低分，导致大量内容优质、增长势头迅猛的潜力“黑马”被系统过滤。如何利用 K-Means 聚类算法结合增长率指标，通过比对历史爆款的“成长轨迹”来挖掘这些“遗珠”，是当前研究的盲区。

3.2 数据孤岛与高对抗反爬壁垒

目前的研究多基于单一平台（主要是起点中文网）的静态数据集，缺乏跨平台的视野。Khder[19]虽然讨论了爬虫技术，但在具体针对中文互联网高难度反爬（如起点中文网的 WOFF 字体加密、纵横中文网的动态渲染）的实战研究较少。现有的学术研究往往回避了这一工程难题，使用的数据往往是二手的、滞后的，导致模型训练结果难以在实际生产环境中落地。

3.3 缺乏对“履约风险”的量化

网络文学存在一个特有的风险——作者断更。现有的评估体系（如蔡新宇的 AHP-FCEM 模型）大多假设作品会完结，忽略了作者更新稳定性的考量。鲜有研究将信息熵（Entropy）引入到作者更新行为的分析中，导致模型可能会给一部即将断更的高热度作品打出高分，误导投资决策。

4 关键技术介绍

4.1 Scikit-learn 与 XGBoost 机器学习框架

在数据挖掘与回归预测领域，Scikit-learn 与 XGBoost 以其高效且稳健的特性，在工业界 IP 价值评估中占据核心地位。Scikit-learn 的核心是基于 NumPy 的矩阵运算，能够标准化处理各式各样的结构化数据。该框架提供了极为丰富的算法库，从基础的线性回归、支持向量机，到高阶的随机森林，一应俱全。而 XGBoost (eXtreme Gradient Boosting) 则凭借其优化的分布式梯度提升库，大幅提升了海量稀疏数据（如

网文点击量、推荐票）的处理效率，显著缩减训练时长。其内置的 Block 结构与缓存感知访问技术堪称一大优势，能够有效处理大规模并行计算。在构建评估模型时，Scikit-learn 的 Pipeline 机制表现出色，它将特征选择、数据转换与模型训练串联成流，即便是处理复杂的多维特征工程，利用这一模块也并不困难。无论是简单的逻辑回归，还是复杂的集成学习模型，用户都能依据 IP 评估任务需求（如分类或回归），轻松定制契合的算法流程。数据处理方面，框架提供的 StandardScaler 与 KFold 工具协同配合，将数据归一化、交叉验证及训练集划分等流程一气呵成，为模型训练提供严谨的数据支持。

4.2 双引擎评估架构 (Dual-Engine Architecture)

双引擎评估架构是本课题针对网络文学全生命周期特性设计的核心算法架构，强调多维度并行处理与特征融合，具有以下显著特性与优势：

全周期并行处理：与传统模型仅关注单一维度的累计数据不同，双引擎架构始终维持对不同生命周期作品的差异化表征，同时并行地运行两个子模型。Engine A（成熟期模型） 类似于高分辨率网络中的语义分支，它同步处理已完结作品的累计月票、核心粉丝率等强交互特征，利用 XGBoost 强大的非线性拟合能力精准预测商业变现价值；Engine B（潜力期模型） 则类似于细节分支，侧重于处理新书的增长率、更新熵及文本情感强度，捕捉微小的潜力信号。这种并行机制使得系统既能精准评估头部 IP 的商业厚度，又能敏锐捕捉冷启动新书的爆发趋势，不会因数据维度的单一而丢失关键信息。

多模态特征融合：架构设计了精巧的特征交叉与融合机制。将文本挖掘得到的非结构化特征（如情感强度 Intensity、题材关键词 Topic）与结构化的数值特征（如点击增长率、IP 地域分布）通过特定的向量拼接方式进行有效融合。各特征子空间之间相互补充、协同工作，让最终输出的评估结果兼具了宏观的市场热度视角与微观的用户口碑视角，显著提升了预测的鲁棒性。

卓越的泛化性能：在处理“长尾分布”的网络文学数据时表现卓越。以新书挖掘为例，双引擎架构通过引入 K-Means 聚类与“IP 基因”相似度匹配思想，将海量未标记的新书映射到高维特征空间，计算其与已改编头部作品的欧氏距离。面对数据稀疏、标签缺失的冷启动场景，系统不再依赖绝对数值的大小，而是基于“波形相似度”给出较为可靠的潜力预测结果；在成熟 IP 评估时，能精细区分“刷榜作品”与“真实高粘性作品”的价值差异，边界划分更为准确。

适应性与拓展性：双引擎架构相对灵活，研究人员可以基于它方便地进行改进与

拓展，融入新的特征模块（如影视改编权权重）、自定义损失函数或是引入时间序列因子，来适配微短剧、有声书等不同下游市场的评估需求，持续推动数字内容资产评估技术的发展与落地。

4.3 数据预处理与增强

冷启动填充与增强：针对新书数据稀疏的问题，本课题引入 基于同类中位数的填充策略（Median Filling），利用同题材、同字数段的成熟作品数据分布来推断新书的缺失特征；同时，引入 SMOTE（合成少数类过采样技术），在特征空间中生成少数类（高价值 IP）的合成样本，增加数据的多样性与平衡性，提升模型对“黑马”作品的泛化能力。

文本向量化与归一化：将非结构化的评论文本转化为计算机可理解的数值。利用 TF-IDF 与 SnowNLP 将文本情感与关键词映射到特定向量空间。同时，对长尾分布极其严重的点击量、打赏数进行 Log-Transformation（对数变换） 和 Min-Max 归一化，将数值统一到 [0, 1] 区间，统一数据分布，加快 XGBoost 模型的收敛速度，让训练过程更稳定高效。

4.4 模型优化与训练

损失函数优化:采用 RMSE（均方根误差）和 RankNet Pairwise Loss（成对排序损失）结合的方式。RMSE 衡量预测评分与真实改编价值（Ground Truth）之间的绝对差异；Pairwise Loss 则针对排序任务，计算预测排名与真实市场排名的误差，促使模型输出更符合市场规律的榜单顺序。这种结合的损失函数能够更全面地评估模型的预测结果，引导模型学习到更准确的价值锚点。

参数调优策略：选用 Grid Search（网格搜索）与贝叶斯优化相结合的策略。针对 XGBoost 的 learning_rate（学习率）、max_depth（树深）、subsample（子采样率）等关键参数进行自动化寻优。在训练初期快速锁定参数范围，中期稳定收敛，后期微调参数，平衡了收敛速度与模型过拟合风险，带着双引擎模型不断优化权重。同时，结合 K-Fold 交叉验证策略，进一步提高评估结果的可靠性。

4.5 模型评估与部署

多维评估指标：依靠 RMSE（均方根误差）、R-Squared（拟合优度）以及 Top-K Recall（前 K 个推荐的召回率）等指标，在验证集、测试集上量化评估模型性能，精准定位薄弱环节加以改进。RMSE 指标评估回归预测的准确性；Recall 指标则综合考

虑了模型挖掘潜在爆款的能力，更全面地衡量模型在商业决策中的实用性。

Web 可视化部署：训练好的模型通过 Flask 框架封装为 RESTful API,结合 Vue.js 前端与 ECharts 图表库，构建交互式的 IP 价值评估平台。系统支持实时输入书籍链接进行推理，满足投资机构、运营人员在版权交易、流量分发等场景下的实时性需求。在部署过程中，设计了 Redis 缓存机制以优化高频查询的响应速度，确保在不同网络环境下都能高效运行。

5 参考依据与总结

5.1 参考依据

本课题的研究内容与技术路线建立在扎实的学术理论与前沿技术基础之上，主要参考依据如下：

理论模型支撑：基于 Eslami (2022) 提出的产品生命周期理论（Product Lifecycle Theory）[16]，本课题确立了“双引擎”分层评估的逻辑起点，即针对不同生命阶段的作品，其价值驱动因子（增长率 vs 存量热度）存在显著差异。这一理论为解决“冷启动”预测失效问题提供了坚实的学理依据。

评价指标构建：参考 蔡新宇(2021)的 AHP-FCEM 模型[11]与姜豪 (2022) 的核心粉丝率研究[8]，构建了包含“基础热度”、“粉丝粘性”、“情感共鸣”与“转化潜力”的多维指标体系，弥补了传统单一点击量指标的片面性。

数据采集：依据 Khder (2021) 对 Web Scraping 技术的综述[19]，设计了 Requests+Selenium 的混合爬虫架构，并结合 fontTools 字体解密技术，成功突破了起点中文网等平台的反爬壁垒。

情感计算：依据 Pavitha (2022) 与 Dhar (2022) 的情感分析研究[17,20]，引入 SnowNLP 对非结构化评论文本进行情感极性分析，量化读者的心理共鸣程度，为 IP 价值评估注入了“内容”维度。

5.2 总结

综上所述，网络文学 IP 价值评估正处于从“经验主导”向“数据智能”转型的关键时期。现有的研究虽然在指标构建上有所建树，但在面对数据孤岛、冷启动预测失效及履约风险量化等实际痛点时，仍显得力不从心。

本课题正是基于这一行业痛点与学术空白，创新性地提出了基于 “双引擎深度

学习架构” 与 “混合反爬攻防策略” 的系统化解决方案。通过构建覆盖 起点中文网与纵横中文网的多源异构数据资产，利用 XGBoost 集成学习与 SnowNLP 情感计算技术，实现 IP 从“孵化期”到“成熟期”的全链路价值刻画。这不仅在工程上突破了跨平台数据融合的技术瓶颈，更在理论上弥补了现有研究在冷启动挖掘与动态风控方面的不足，为数字文化产业的版权交易、内容投资与流量分发提供了科学、客观且具可解释性的决策工具，具有显著的学术创新价值与广阔的商业应用前景。

参考文献

[1] 李慧. 跨文化传播视域下玄幻仙侠类网络小说 IP 的共情研究[D]. 吉林大学, 2024.

[2] 刘恒. 网络文学 IP 影视化和衍生开发价值评估研究[D]. 云南财经大学, 2024.

[3] 薛欣雨. 网络文学 IP 转化价值评估研究[D]. 兰州财经大学, 2024.

[4] 刘燕南, 李忠利. 网络文学 IP 价值评估体系探析[J]. 现代出版, 2021(01): 27-33.

[5] 桑子文, 金元浦. 网络文学 IP 的影视转化价值评估模型研究[J]. 清华大学学报(哲学社会科学版), 2019, 34(02): 134-142.

[6] 李玮. 网络文学发展新趋势[J]. 传媒, 2024(02): 15-18.

[7] 冯莉然. 网络文学 IP 电影改编权价值评估——以《少年的你》为例[D]. 山西财经大学, 2023.

[8] 姜豪. 网络文学影视改编权价值评估研究——以《诡秘之主》为例[D]. 中南财经政法大学, 2022.

[9] 勾娜. 大数据背景下网络文学 IP 的衍生发展探析[J]. 文化产业, 2020(02): 25-29.

[10] 姜小薇. 新媒体时代可视化新闻报道质量提升路径探索[J]. 新闻研究导刊, 2024, 15(19): 106-109.

[11] 蔡新宇. 基于 AHP-FCEM 的网络文学数据资产价值评估研究[D]. 东北财经大学, 2021.

[12] 杨舒雅, 肖文, 李娜, 等. 大数据时代网络文学的研究趋势与现状——基于文献计量和 CiteSpace 的可视化分析[J]. 科技传播, 2023, 15(03): 91-94.

[13] 周存. 基于在线评论数据挖掘的图像小说读者需求分析[D]. 河北大学, 2023.

[14] 张启宁, 吴国俊. 基于 Python 网络爬虫技术的乡村旅游数据采集与分析[J]. 产业科技创新, 2023, 5(06): 66-68.

[15] 魏焱, 杜斌, 等. 基于自然语言处理技术的电力文本挖掘与分类[J]. 自动化技术与应用, 2021, 40(10): 60-63.

[16] Eslami, S. P., Ghasemaghaei, M., & Hassanein, K. Understanding consumer engagement in social media: The role of product lifecycle[J]. Decision Support Systems, 2022, 162: 113707.

[17] Dhar, S., & Bose, I. Walking on air or hopping mad? Understanding the impact of emotions, sentiments and reactions on ratings[J]. Decision Support Systems, 2022, 162: 113769.

[18] Li, K., Zhou, C., Luo, X. R., et al. Impact of information timeliness and richness on public

engagement[J]. Decision Support Systems, 2022, 162: 113752.

[19] Khder M A. Web scraping or web crawling: State of art, techniques, approaches and application[J]. International Journal of Advances in Soft Computing & Its Applications, 2021, 13(3).

[20] Pavitha N, Pungliya V, Raut A, et al. Movie recommendation and sentiment analysis using machine learning[J]. Global Transitions Proceedings, 2022, 3(1): 279-284.