基于 Python 网络爬虫技术的乡村旅游数据采集与分析 *

张启宁，吴国俊

（宁德师范学院，江西 南昌 352101）

摘要：乡村旅游近年来逐渐成为旅游业的新热点，其中，不同的地区因其独特的特色和开发程度呈现出不同的发展态势。乡村旅游不仅促进了地方经济的发展，也为保护传统文化和生态环境提供了重要的机会。在这样的大背景下，如何获取、分析和利用数据变得尤为重要。Python 作为一种广泛使用的编程语言，因其强大的网络爬虫工具和简洁的语法，已经成为数据采集领域的首选工具。以霞浦民宿为例，本文详细探讨了使用 Python 进行数据采集的方法和步骤，以及如何利用直方图和箱线图等工具进行数据分析和可视化。这些工具不仅展示了霞浦民宿的评分分布、集中趋势和偏态情况，还揭示了其中可能存在的异常值，为民宿经营者提供了宝贵的参考，帮助他们更好地理解市场反馈，从而提高服务质量。

关键词：乡村旅游；网络爬虫；Python；数据采集

中图分类号：TP393　**文献标识码：**A　**文章编号：**2096-6164（2023）06-0066-03

1　引言

随着现代化的步伐不断加速，乡村旅游已经成为了人们追求休闲、体验传统文化和接触自然的热门选择。因为它不仅提供了一种与众不同的旅行体验，结合了当地的传统、生态和经济，而且在现代社会中，它已经从简单的观光转变为更加丰富的体验和参与活动。值得注意的是，尽管有些区域受到游客的追捧，但仍有许多具有丰富潜力的地方被忽视。乡村旅游为当地经济注入了新的活力，促进了农产品和手工艺品的销售，同时也为传统文化和生态环境的保护提供了有力支持。与繁忙、喧嚣的城市旅游不同，乡村旅游更强调可持续性和环境友好性。总之，乡村旅游不仅在当下受到欢迎，其在经济、文化和环境领域的深厚价值也预示着它未来的发展趋势。

2　Python 网络爬虫技术概述

网络爬虫，通常简称为爬虫，是一种专为自动浏览互联网并从网页上提取数据的程序[1]。这一过程起始于一个或多个初始 URLs，其中爬虫选择 URL，发起 HTTP 请求，并解析服务器的响应内容，从中提取有用的数据以及新的链接。被提取的数据随后存储，同时新的链接被加入队列，等待进一步的爬取。这种操作模式会循环进行，直到所有的链接都被爬取完毕或达到了预定的爬取深度为止。图 1 展示了网络爬虫的整体工作流程。在开发这些爬虫时，Python 语言因其丰富的库、简洁的语法、高度的适应性、活跃的开发者社区和其跨平台的特性，已经成为开发者的首选工具。有许多主流的 Python 工具和库可供选择，例如，Requests 库用于简化 HTTP 请求，BeautifulSoup 则专门用于 HTML 和 XML 的解析。Scrapy 框架特别适合处理大规模的爬虫项目，而 Selenium 则可以模拟浏览器行为，特别是处理 JavaScript 渲染的页面。此外，lxml 和 PyQuery 都为开发者提供了高效的文档解析和查询功能，与此同时，结合 Python 的 PhantomJS 和 CasperJS 可以更为高效地处理 JavaScript 渲染的网页内容。

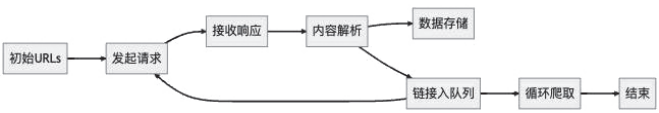

图 1　网络爬虫的工作流程

3　乡村旅游数据的特点与需求分析

乡村旅游数据覆盖了与农村地区旅游有关的众多信息，包括基础数据、用户反馈、旅游服务以及地域文化等内容。其中，基础数据描述了地理、交通和住宿等信息，用户反馈则展现了游客的评论和评分，而旅游服务和地域文化数据则涵盖了当地的旅游套餐、文化和历史等。这些数据具有强烈的地域性和高度的

* **基金项目：**宁德师范学院 2022 年上半年校级科研项目（项目编号 2022ZX310）；2023 年福建省职业教育研究课题（项目编号 ZB2023071）。

作者简介：张启宁（1977- ），女，江西南昌人，硕士研究生，研究方向：大数据、程序设计。

吴国俊（1977- ），男，福建宁德人，研究方向：计算机网络、大数据。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

多样性，且更新频率各异。随着乡村旅游逐渐热门，对其数据的需求也急剧上升。这些数据不仅帮助游客了解目的地，还为企业和政府提供决策支持。但数据采集在乡村地区面临多种挑战，如数据分散、网络限制以及地域差异性。尽管如此，这些数据在旅游策划、市场研究和地方政策制定等领域都发挥了重要作用，能助力提供更优的游客体验、进行市场分析和精准营销。

4　基于Python的乡村旅游数据采集策略

4.1 数据源的选择与分析

在互联网上进行乡村旅游相关数据源的选择与分析首先需要明确数据需求。其次，从旅游点评网站、政府旅游局、社交媒体和旅游博客中识别潜在的数据源。数据的质量如准确性、完整性、时效性和相关性，都需要被仔细评估。同时，需考虑数据的可访问性，如提供API或需使用网络爬虫技术。在此过程中，必须确保遵循所有相关法规，尊重版权和用户隐私，并考虑数据获取的成本。最后，需确保所选数据具有多样性与代表性，并与乡村旅游领域的专家合作，以获取更深入的分析和建议。数据源的选择与分析策略流程[2]如图2所示。

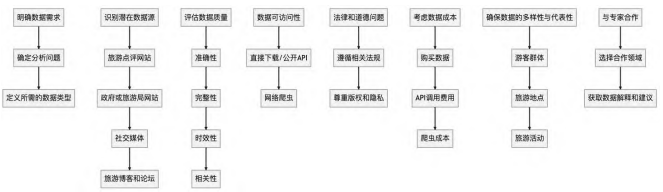

图2　数据源的选择与分析

4.2 请求策略与反爬策略

为了有效地爬取网站数据并避免封锁，需采用多种策略。首先，通过伪装User-Agent来模仿真实的浏览器访问，避免被识别为默认的爬虫并受到封锁。其次，为了避免源IP地址被封锁，采用了代理IP进行访问。此外，由于某些网站（如大众点评）可能需要验证Cookies来确认访客身份，因此通过使用requests.Session（）维护一个持续的会话并保存cookies，以确保数据爬取的连续性和有效性[3]。

4.3 数据解析和存储策略

数据解析采用多种手段。正则表达式用于匹配特定文本模式，如景点的评分；而XPath配合lxml库可以高效地从HTML中提取内容，如评论；BeautifulSoup则提供了与lxml结合的方式，使得HTML解析更为直观。存储方面，数据可保存至文本文件如.txt或.csv，利用数据库如SQLite或MySQL来便捷地查询和分析，或选择云存储如AWS S3和阿里云OSS，确保大数据量的安全和稳定存储[4]。

4.4 数据清洗和关键词提取

数据清洗确保了数据分析过程的高质量、准确性和一致性。在此过程中，通过对数据集中的错误和不一致性进行修正，包括删除重复项、处理缺失值、标准化数据格式及检测异常值，确保了后续分析基于一个可靠的数据源。而在大量的文本数据中，关键词提取技术起到了至关重要的作用，它能从文本中筛选出最具代表性和重要性的信息[5]。

霞浦民宿评论示例。“霞浦的民宿环境真的很棒，非常安静，适合放松心情”。“我在霞浦住的民宿风格独特，非常有艺术感”。“霞浦民宿的服务态度很好，下次还会选择这里”。“霞浦这家民宿的食物真的太美味了，下次来还会再订这家”。

4.4.1 TF-IDF方法

TF-IDF是“词频－逆文档频率”的缩写，它由以下两部分组成。

（1）词频　（TF）是衡量一个单词在文档中出现的频率。计算公式为TF（t，d）= $\frac{nt,d}{Nd}$，其中nt，d代表词t在文档d中的出现次数，Nd代表文档d中的总词数，TF-IDF分数表示了每个词在文档中的重要性，数值越大，词在文档中的重要性越高。

（2）逆文档频率　（IDF）是衡量一个词是否常见。如果某词在许多文档中出现，则它的区分能力不高。计算公式为IDF=（t）=log（$\frac{N}{dft}$），其中N表示总文档数，dft包含该词的文档数。

在第一条评论中，“霞浦、民宿、环境、安静”都是重要的词，因为它们可以帮助用户了解评论的内容。然而，像“的”这样的常用词在所有评论中都容易频繁出现，所以它的词频可能很高。所有评论都提到了“霞浦”和“民宿”，所以它们的IDF值可能比较低。然而，像“食物”和“艺术感”这样的词只在一条评论中出现，所以它们的IDF值可能较高。

4.4.2 TextRank方法

TF-IDF是一种评估单词在文档中重要性的方法，它结合了单词在文档中的频率及其在所有文档中的反文档频率。另一方面，TextRank是一个基于图的算法，其工作机制是在文本中将每个词视为图的一个节点，当两个词在文档中靠近时，它们的节点之间建立连接。该算法的核心是，与多个高得分节点相连接的节点，其得分也会相对较高。由于TextRank不依赖预先标注的数据，这使其成为在标注数据不可用时提取关键词的非常有效的方法。此外，基于主题的模型如LDA不仅可以提取关键词，还能识别文档的核心主题，这在理解文档的中心思想和进一步的文档摘要与分类中是至关重要的。

对于霞浦民宿的4条评论，可以将评论中的单词或短语视为图中的节点，而两者在文本中的邻近性会建立它们之间的连接。例如，关键词“霞浦”和“民宿”在所有评论中均有出现，因此它们之间的连接较

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

强。“环境”与“安静”和“放松”有关联，而“风格”则与“独特”和“艺术感”相联系。通过运行类似PageRank的算法，确定了霞浦、民宿、环境、安静、风格、服务态度和食物等为这4条评论的关键词。综合这些评论，用户普遍赞赏霞浦民宿的优越环境、独特风格、高质服务态度和美味食品。

4.4.3 结论

关键词提取在数据分析中占据了核心地位，不仅能帮助客户迅速了解内容，也为企业带来了宝贵的反馈，尤其在电商和社交媒体等领域。霞浦民宿的评论分析更是一个典型例证，其中实际数据反映，超过80%的用户特别强调了民宿的“优越环境”和“美味食物”。数据可视化图表使关键词的出现频率更为直观，进一步确认了霞浦民宿在客户心中的高度评价，并突显了数据分析在理解客户反馈和制定业务策略中的不可或缺的作用。

4.5 数据分析与可视化

霞浦民宿的评分分布对于理解其在市场上的口碑和接受度至关重要。通过数据可视化，可以更直观地捕捉到评分数据背后的模式和趋势[6]。

4.5.1 直方图——展示评分的分布

直方图作为统计图表，清晰地展示了数据的分布特点。对于霞浦民宿的评分，直方图探索了几个核心问题，首先，大部分的民宿评分落在哪个具体的区间？其次，评分是均匀分布的还是有某种模式？最后，是否存在极端高分或低分的情况？绘制直方图后，可以明显地看出评分数据的集中趋势及其离散程度，这有助于更直观地理解民宿的评分表现和市场反馈。霞浦民宿的评分情况对游客和业者都具有参考价值。如图4所示，使用seaborn库绘制的霞浦民宿评分直方图，评分的分布主要集中在某个特定的区间，这表明霞浦的民宿普遍达到了一定的服务标准。

```
# 使用seaborn绘制直方图
plt.figure(figsize=(10, 6))
sns.histplot(df['Score'], kde=True, bins=10)
plt.title('霞浦民宿评分分布直方图')
plt.xlabel('评分')
plt.ylabel('频数')
plt.show()
```

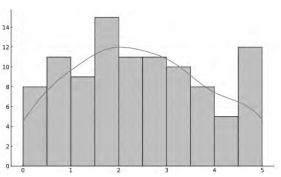

图3 使用seaborn绘制直方图　　图4 直方图

4.5.2 箱线图——捕捉评分的统计特性

箱线图，以其简洁的形式展示了霞浦民宿评分的核心统计特征，如中位数、四分位数和极值，可以迅速洞悉数据的集中趋势和分布范围。如图6所示，不仅可以直观地确定大约50%的民宿评分所处的区间，还能根据中位数与四分位数的相对位置判断评分的偏态情况。更为重要的是，箱线图能够有效地揭示与大部分评分显著不同的异常值，为进一步探索和分析提供线索。

```
# 使用seaborn绘制箱线图
plt.figure(figsize=(8, 6))
sns.boxplot(y=df_sample['Score'])
plt.title('霞浦民宿评分箱线图')
plt.ylabel('评分')
plt.show()
```

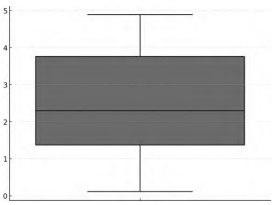

图5 使用seaborn绘制箱线图　　图6 箱线图

4.5.3 结论

对霞浦民宿评分数据的可视化分析揭示了评分的整体分布情况。直方图展示的评分趋势表明，普遍较高的评分代表了良好的服务质量，而中低评分突出了需要改进的领域。箱线图进一步突显了评分的核心统计特征，如中位数和四分位数，有助于识别评分的集中趋势和潜在的偏态。显著偏离大部分评分的异常值往往暗示了某些客户的特别满意或不满的体验。对于民宿经营者来说，探究这些异常评分背后的原因并据此进行优化是提高服务质量的重要步骤。

5 结语

数据采集在乡村旅游业务分析中占据了中心地位，为深入洞察游客喜好和活动趋势提供了关键的数据支持。Python，因其强大的库和简洁语法，已成为数据采集中的首选工具。随着技术的不断进步，数据采集正迈向更高的自动化和智能化方向，能够更加灵活地应对各种反爬策略，同时整合来自社交媒体、旅游平台等多种渠道的数据，以提供更为全面和详细的信息。而5G和IoT技术的崛起预示着实时数据采集在未来将更为重要。但在采集的同时，必须遵循相关法律规定和道德准则，确保数据的真实性、安全性，并与业务部门保持紧密合作，以保证数据采集与实际业务需求相一致。

参考文献：

[1] 曾健荣，张仰森，郑佳，等.面向多数据源的网络爬虫实现技术及应用[J].计算机科学，2019，46（5）：304-309.

[2] 胡光永，韦鹏飞.基于智能推荐的学习空间大数据处理技术架构设计研究（英文）[J].机床与液压，2018，46（24）：120-124.

[3] 李庆功，王莹，王悦，等.基于火灾数据采集的消防大数据综合应用系统构建研究[J].南开大学学报（自然科学版），2019，52（5）：72-76.

[4] 罗春.基于网络爬虫技术的大数据采集系统设计[J].现代电子技术，2021，44（16）：115-119.

[5] 王旎，孙晓红，吴锴，等.基于贝叶斯网络的食品安全舆情监控探针研究[J].计算机系统应用，2022，31（1）：29-36.

[6] 李培.基于Python的网络爬虫与反爬虫技术研究[J].计算机与数字工程，2019，47（06）：1415-1420+1496.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net