基于自然语言处理技术的电力文本挖掘与分类

魏 焱，杜 斌，邓旭阳，何 杰

(广东电网有限责任公司，广东 广州 510600)

摘 要：为深层挖掘电力数据文本蕴藏的信息，本文基于自然语言处理技术分析了电力文本挖掘与分类流程，通过分词技术分析文本内容，提取文本特征，并构建分类器模型以自动分类文本，最后以实例分析了电力文本挖掘与分类的实际效果。结果表明，中文电力数据文本挖掘准确度较高，适用范围广泛，方式方法灵活，可及时准确挖掘隐藏的关键信息，为分析客户用电诉求与投诉要求提供了完善的数据依据；以文本自动分类分析，构建的分类器模型查准率与准确率相对较高，且调优之后分类器模型可更加准确地识别出热点事件投诉工单。

关键词：自然语言处理技术；投诉工单；文本挖掘；文本分类

中图分类号：TP391.1 文献标识码：A 文章编号：1003-7241(2021)10-0060-04

Power Text Mining and Classification Based on Natural Language Processing Technology

WEI Yan, DU Bin, DENG Xu-yang, HE Jie

(Guangdong Power Grid Co., Ltd., Guangzhou 510600 China)

Abstract: In order to deeply mine the information contained in the power data text, this paper designs and analyzes the power text mining and classification process based on natural language processing technology, analyzes the text content through word segmentation technology, extracts the text features, and constructs a classifier model to automatically classify the text, and finally analyzes the actual effect of power text mining and classification with an example. The results show that Chinese power data text mining has high accuracy, wide range of application, flexible methods, timely and accurate mining of hidden key information, which provides a perfect data basis for the analysis of customers' power demands and complaints; the classifier model constructed by automatic text classification analysis has relatively high accuracy and accuracy, and the optimized classifier model can more accurate identification of hot event complaint work order.

Key words: natural language processing technology; complaint work order; power; text mining; text classification

1 引言

文本挖掘也称之为文本数据挖掘，类似于文字分析，即文本处理中生成高质量信息。而高质量信息一般以分类与预测生成，例如模式识别。文本挖掘涉猎输入文本的处理过程，生成结构化数据，最终评语并解释输出。高品质文本挖掘即既定组合的关联性、新颖性、趣味性。典型文本挖掘方法主要包含文本聚类、文本分类、实体挖掘、精确分类、观点分析、文本摘要、实体关系模型。就电力系统而言，文本挖掘的作用不可忽视。电力数据自身具有一定复杂性与全面性，需基于计算机系统实现电力数据文本挖掘，才可充分了解电力系统用电具体情况，并预测未来趋势。但是既有文本挖掘主要是针对英文词汇进行，其只需要通过空格区分即可，所以基于英文的文本挖掘不需要考虑文本预处理，但是中文文本只有句子与段落可明显区分，想要分割中文词汇，难度相对较大，这也就严重阻碍了中文电力数据文本挖掘工作的开展，而我国电力数据主要以中文文本呈现，据此本文以自然语言处理技术为载体研究分析了电力数据中文文本挖掘与分类[1]。

2 基于自然语言处理技术的电力文本挖掘与分类设计

收稿日期：2020-06-11

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

基于自然语言处理技术的电力文本挖掘流程[2]具体如图1所示。

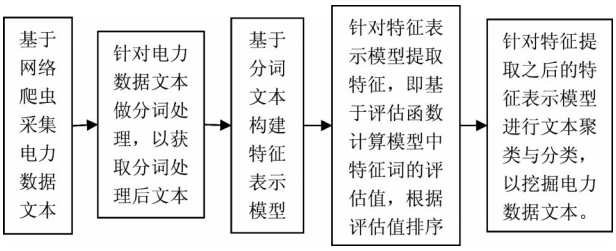

图1 电力文本挖掘流程

2.1 数据预处理

就电力文本挖掘可知，其处理对象为海量文本，其中内容是由人类自然语言所构成的，计算机无法直接阅读理解。具体而言，自然语言结构过于复杂，包含语法、语义、语用等等；易于产生歧义，需基于语境信息才可理解语言内涵；文本中存在噪声数据，直接分析很容易错误引导最终结果。因此文本挖掘的关键问题在于有效解决文本结构化表示，促使其可被计算机阅读理解，且需反映文本真实特征，此过程即文本预处理，也是特征提取。数据预处理是为了转变半结构或无结构文本为结构化数据文本，以利于计算机系统阅读与理解，从而为数据挖掘做好准备工作。通常来讲，中文文本预处理包含分词、特征表示、提取三部分[3]。

2.1.1 文本分词

分词即将整句或者整段连续的文字根据既定规则划分为词语。在英文文档处理时，单词都是以空格分隔，无需设计算法进行文本分词处理。而文本中虽然单字、整句、段落存在明显分节符，但是词语无法直接区分。因此中文文本分词相对复杂，而作为独立研究方向，其中也存在许多重要应用，例如信息检索、中外对译、自动摘要、自动分类等等。特别是随着网络数据快速增长，中文信息也日益膨胀，中文文本分词的重要性也就越来越突出。当前中文分词方法主要有两种，即基于词典的分词法与基于标注的分词法。基于词典的分词法需构建内存充足的机器词典，根据一定策略将待分析字串与词典内词条相匹配；基于标注的分词法属于构词法，将分词过程作为字在语句中的标注问题，通过标注汉字，以字生成词，即组词，此方法充分考虑了文字词语出现的频率信息以及上下文语境信息。

2.1.2 特征表示

作为数据预处理的首要步骤，分词同时也是数据结构化初始阶段。而特征为非结构化数据转变为结构化数据的重要载体。特征表示模型主要有布尔逻辑模型、向量空间模型、概率模型。

2.1.3 特征提取

通过特征表示之后，需进行特征选择，也就是特征提取。基于特定评估函数计算特征词评估值，根据大小进行排序，以选择所需特征词，也称为评估函数法。所以特征提取的关键在于评估函数设计，应用最为广泛的评估函数主要包括有互信息、信息增益、统计法等等。

2.2 文本聚类

数据预处理之后就是文本挖掘的关键部分，即文本聚类。电力文本聚类是非监督分类，不具备标签信息，自动分类文本。而文本数据在特征提取与向量化之后，聚类过程与机器学习聚类过程相同[4]。常用聚类算法包含划分法、层次法、图论聚类法等等，相应代表算法即K-Means算法、DBSCAN算法等。

2.3 文本分类

电力文本分类目的更加明确，是监督学习过程。文本分类即针对给定文本，给出预定义的类别标号，准确高效分类文本，是海量数据管理任务的重要构成环节。在数据预处理之后，文本分类方法也是各式各样，应用最为广泛的有朴素贝叶斯算法、K-近邻算法、决策树算法、神经网络与支持向量机算法。而深度学习也适用于文本分类，且分类效果良好。

电力文本分类流程[5]具体如图2所示。

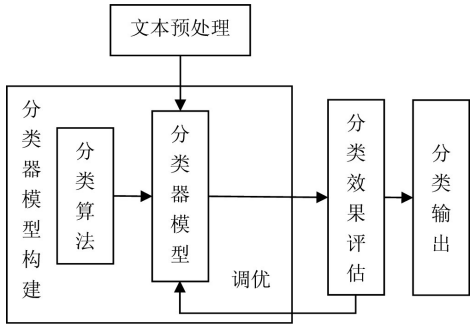

图2 电力文本分类流程

分类器模型构建是指基于相关算法，以文本预处理后数据为载体生成分类器模型，以此模型自动分类新型文本数据。分类器分类效果评估是电力文本自动分类的关键环节，而评估指标的有效性与试验测试结果可信度息息相关。

电力文本分类常用评估指标主要包含查全率(W)、查准率(V)、准确率(W')、遗漏率(G)，以此评估文本分类效

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

果。以列联表加以表征，具体如表1所示。

表1 列联表

	机器评估是	机器评估不是
人工评估是	A	C
人工评估不是	B	D

彼此关系表示为：

$$W=\frac{A}{A+C},V=\frac{A}{A+B}$$
$$G=1-W=\frac{C}{A+B} \tag{1}$$
$$W'=\frac{A+D}{A+B+C+D}$$

3 实例分析

以自然语言处理技术着手，针对电力投诉工单文本进行深层挖掘，通过分词技术分析文本内容，以分词结果为辅助提取特征，掌控电力投入主要问题，采取针对性的个性化服务策略，以提高客户满意度。

3.1 文本分词实现

电力文本分词即通过计算机自动切分词语，利用大数据软件Python与隐马尔可夫模型，进行电力投诉受理内容分词处理[6]。分词结果具体如表2所示。

表2 电力文本分词结果

句子	分词结果
客户来电表	客户；来电；今早；一位；供电公司；女性；工作人员；家中；告知；母亲；电量；阶梯；电
客户从去年	客户；去年；电压；长时间；低；影响；生活；居民；生产；解决；供电公司；核实处理；停电
户号为444	户号；4532678450；客户；供电公司；男性；费时；态度；差；工作人员；情况；工作；来电
客户来电投	客户；投诉；拨打；95598；保修；抢修；电话；告知；问题；回复；人员；19983764520
客户来电反	客户；来电；地点；计划；停电；公告；时间；停电；信息；短信；通知；拨打；电话；现场
客户来电源	客户；湖南省；长沙市；雨花区；东塘街道；芙蓉南路社区；组；号；前期；线路；改造；施工

3.2 特征提取实现

针对电力文本数据分词处理，各单词都可作为文本标识特征，所有特征在电力文本集中的出现次数[7]具体如表3所示。

3.3 分类器模型实现

基于大数据算法，就试验数据文本构建分类器模型，以此模型自动分类电力投诉工单数据文本，充分了解热点事件于不同业务中的具体分布状态，通过结果分析，设计有效应对策略，以实现电力主动服务，提高客户满意度与忠诚度，减少投诉次数，增大客户粘性。

表3 不同特征出现次数

客户	停电	评估	来电	接错	的	故障	是	用电	抢修	营业厅
1115	1093	1029	741	75	526	492	128	116	77	681
电表	同时	电杆	抄表	更换	导致	今天	由于	周围	排除	供电所
46	35	26	25	19	10	9	6	6	61	112

3.3.1 明确模型

以停电为例，在投诉工单中随机选择疑似停电工单与既定比重非停电工单为训练集。建立决策树C_5树、SVM算法、C&R树等算法的文本分类模型，选择查全率、查准率、准确率、遗漏率为评估指标，对分类器模型的整体效果进行比较分析，最终选择决策树C_5树模型为停电的分类器模型。

3.3.2 效果评估

输入待分类电力投诉工单于决策树C_5树模型加以分类处理，并评估分类效果，结果具体如表4所示。

表4 分类效果评估结果

评估指标	评估结果
查全率W/%	94.5
查准率V/%	34.9
准确率W'/%	80.6
遗漏率G/%	8.9

由表4可知，决策树C_5树模型的查全率大约在94.5%，而遗漏率大约在8.9%，对于疑似停电投入工单可大体全部识别；基于查准率与准确率指标，其中查准率约为34.9%，准确率约为80.6%，这就说明尽管可大致识别全部疑似停电工单，但是判断明确其他热点工单为停电工单，所以需进一步调优改进分类器模型。

就分类器模型调优改善基于三层次加以完成，即丰富优化同义词库与专业术语词库，以提高分词结果精确性；特征词提取需更加精确化；调参决策树C_5树算法，即调优改进模型深度与叶子节点。在调整分类器模型之后，输入训练集工单于模型内加以分类处理。在模型调优之后分类效果评估结果具体如表5所示。

由表5可知，通过调优之后，分类器模型的查准率与准确率都实现了明显提高，遗漏率虽有所增大，但是依旧控制在可接受之内。基于训练集数据验证，调优之后分类器模型可更加准确地识别出热点事件投诉工单[8]。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表5 模型调优之后分类效果评估结果

评估指标	评估结果
查全率W/%	90.0
查准率V/%	95.1
准确率W'/%	94.4
遗漏率G/%	12.6

基于分类处理的热点事件投诉工单与营销部门业务相互关联，可明确各种类型业务对于客户满意度与投诉度的影响程度，并提出科学有效的改进方式方法与解决对策，以此在提高客户满意与减少客户投诉的同时，强化客户忠诚度，从而促进供电企业实现长远稳定发展。

4 结束语

综上所述，本文基于自然语言处理技术研究了电力文本挖掘与分类，以投诉工单为例分析了电力文本挖掘与分类器模型的实际效果，结果表明，利用大数据分析技术、分词分析法等进行投诉工单文本挖掘，突破了既有对客户投诉需求模糊不清的限制，以掌握电力客户投诉问题，提出针对性、个性化服务策略，以显著提升客户满意度与忠诚度；中文电力数据文本挖掘准确度较高，适用范围广泛，方式方法灵活；分类器模型的查准率与准确率非常高，且调优之后分类器模型可更加准确地识别出热点事件投诉工单。

参考文献：

[1] 汪崔洋，江全元，唐雅洁，等.基于告警信号文本挖掘的电力调度故障诊断[J].电力自动化设备，2019，39(4)：126−132.

[2] 杜修明，秦佳峰，郭诗瑶，等.电力设备典型故障案例的文本挖掘[J].高电压技术，2018，44(4)：1078−1084.

[3] 曹湘，李誉坤，钱叶，等.基于混合神经网络的电力短文本分类方法研究[J].计算机与数字工程，2019，47(5)：1145−1150.

[4] 邱剑.电力中文文本数据挖掘技术及其在可靠性中的应用研究[D].杭州：浙江大学，2016.

[5] 曹靖，陈陆燊，邱剑，等.基于语义框架的电网缺陷文本挖掘技术及其应用[J].电网技术，2017，41(2)：637−643.

[6] 李锐，张伟彬.基于TF−IDF算法和LDA主题模型数据挖掘技术在电力客户抱怨文本中的应用[J].自动化技术与应用，2018，37(11)：46−50.

[7] 祝春捷，潘坚跃，王译田，等.基于结构化表达的电力运维文本分析[J].电子设计工程，2019，27(17)：53−58.

[8] 彭路，朱君，邹云峰.基于深度神经网络的电力客户诉求预判[J].计算机与现代化，2020(5)：22−28.

作者简介：魏焱(1985-)，男，工程师，硕士，研究方向：智能电网信息化。

(上接第46页)

4 结束语

针对传统方法存在的一系列问题，设计并提出一种基于改进k−中心聚类的P2P模式合作伙伴选择方法。仿真实验结果表明，所提方法能够有效提升收敛率，降低平均迭代次数以及最优解耗时，获取最佳合作伙伴。

但是所提方法在实际研究的过程中，由于受到多方面因素的限制，导致其仍然存在一定的不足，后续将重点针对以下几方面的内容进行研究：

(1) 所提方法未能考虑P2P模式合作伙伴选择成本问题，同时也没有针对该方面的内容进行研究，后续将进一步进行分析。

(2) 所提方法的运行效率当前也并不是十分理想，后续将加强该方面内容的研究。

参考文献：

[1] 袁梦琪，李忠富，李龙.基于向量夹角余弦的SI住宅虚拟企业合作伙伴选择方法[J].土木工程与管理学报，2018，35(1)：121−126.

[2] 肖赟，魏朗.旅客联程联运伙伴选择方法研究[J].北京交通大学学报(社会科学版)，2018，17(1)：49−55.

[3] 李华强，刘浩学，韩言虎.多式联运联盟合作伙伴选择[J].公路交通科技，2018，35(8)：152−158.

[4] 兰丽娜，石瑞生，勾学荣.基于学习行为模型的学习伙伴推荐方法研究[J].现代教育技术，2018，28(4)：67−73.

[5] 赵金辉，王学慧，周玉.需求驱动的虚拟企业合作伙伴选择[J].控制与决策，2019，34(12)：125−132.

[6] 蹇洁，王咪琳，安世全，等.协同产品创新联盟伙伴选择决策[J].计算机集成制造系统，2019，25(3)：752−763.

[7] 陈海华，邵亚丽，张莉敏，等.基于群搜索算法的虚拟企业伙伴选择问题[J].电子测试，2018(21)：72−73，65.

[8] 吴菲菲，李睿毓，黄鲁成.企业跨产业研发合作伙伴识别与选择[J].情报杂志，2019，38(9)：42−48.

作者简介：李珊珊(1988-)，女，硕士研究生，讲师，研究方向：工程项目管理，PPP项目风险研究。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net